

## Rappels et Introduction

### 1 Moindres Carrés

$$Y = X\beta^* + \epsilon, \quad \epsilon \sim \mathbf{N}(0, \sigma^2 Id_p).$$

$Y$  : observation,  $Y \in \mathbb{R}^n$ .

$X$  : Covariables("features"),  $X \in \mathbb{R}^{n \times p}$ .

$\beta^* \in \mathbb{R}^p$  : vecteurs des coefficients.

$\epsilon \in \mathbb{R}^n$  ; bruits (d'observations).

#### L'estimateurs des moindres carrés (MCO) (LS) :

$$\hat{\beta}^{obs} \in \operatorname{argmin}_{\beta \in \mathbb{R}^n} \frac{1}{2} \|y - X\beta\|_2^2$$

$$f(\beta) = \beta^T \frac{X^T X}{2} \beta + \frac{1}{2} \|y\|^2 - \langle y; X\beta \rangle, \quad \text{avec } \langle y; X\beta \rangle = y^T X\beta = \beta^T X^T y = \langle \beta; X^T y \rangle$$

$X^T X$  est appelée matrice de Gram.

$$X^T X = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} (x_1 \cdots x_p) = \begin{pmatrix} \|x_1\|^2 & & \\ & \ddots & \\ & & \|x_p\|^2 \end{pmatrix}$$


$$X^T X = [\langle X_i; X_j \rangle]_{(i,j) \in [1,p]^2}$$

**Remarque :** Souvent  $X_1 = \mathbb{1}_n = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \in \mathbb{R}^n$

**Conditions du premier ordre :**

$$\hat{\beta}^{OLS} \in \operatorname{argmin}_{\beta \in \mathbb{R}^n} \implies \nabla f(\hat{\beta}^{obs}) = 0$$

$f$  est  $c^\infty$  et donc  $\nabla f(\hat{\beta}^{OLS}) = 0$  est nécessaire en un minimum local :



Si besoin, calculer  $f(\beta + h) - f(\beta)$  et trouver le gradient :

$$\nabla f(\beta) = X^T X \beta - X^T y$$

$$\nabla f(\hat{\beta}^{OLS}) = 0 \Leftrightarrow X^T (y - X \hat{\beta}^{OLS}),$$

où  $(y - X \hat{\beta}^{obs})$  sont des résidus.

$$\Leftrightarrow \forall j \in [1, p], \langle X_j, y - X \hat{\beta}^{obs} \rangle = 0$$

**Remarques :**

— **existence :** On a besoin que  $XX^T > 0$  (Semi-défini positif).

— Si  $X^T X$  est inversible alors elle reste semi défini positive et il y a encore l'existence d'une solution.  
Pour s'en convaincre :  $f$  est continue et coercive.

$$f(\beta) \longrightarrow +\infty$$

$$\|\beta\| \longrightarrow +\infty$$

- **Unicité :** Avec les conditions normales de premier ordre (C.N.O) on a :  $X^T X \hat{\beta}^{OLS} = X^T y$ , qui donne un système linéaire.

L'unicité est garantie si  $X^T X$  est inversible, et on a :

$$X^T X \text{ est inversible} \Leftrightarrow \text{rang}(X) = p \text{ (hypothèse de plein rang en colonne)}$$

**Attention :** pour cette hypothèse (de plein rang en colonne),  $p$  doit être plus petit ou égal à  $n$  ( $p \leq n$ ).

Sous cette hypothèse,

$$(\text{unique}) \hat{\beta}^{OLS} = (X^T X)^{-1} X^T y$$

Sinon : Une solution possible s'écrit :

$$\hat{\beta}^{ls} = X^+ y,$$

où  $X^+$  est la pseudo-inverse de  $X$ .

## 2 La décomposition en valeurs singulières ( En anglais : Singular Value Decomposition, SVD)

### 2.1 Rappels

1- Une matrice  $U \in \mathbb{R}^{n \times n}$  est dite orthogonale si elle vérifie

$$U^T U = U U^T = \text{Id}_n$$

ou  $\forall (i, j) \in \{1, \dots, n\}^2 \quad \mathbf{u}_i^T \mathbf{u}_j = \langle \mathbf{u}_i, \mathbf{u}_j \rangle = \delta_{i,j}$ .

2- **Théorème spectral :**

Une matrice symétrique  $A \in \mathbb{R}^{n \times n}$  est diagonalisable en base orthonormée, i.e., il existe  $\lambda_1 \geq \dots \geq \lambda_n$  et une matrice orthogonale  $U \in \mathbb{R}^{n \times n}$  telle que :

$$A = U \text{diag}(\lambda_1, \dots, \lambda_n) U^T \text{ ou } AU = U \text{diag}(\lambda_1, \dots, \lambda_n)$$

Les  $\lambda_i$ ,  $i = 1, \dots, n$  sont les valeurs propres de  $A$  et les  $\mathbf{u}_i \in \mathbb{R}^n$  sont les vecteurs propres associés.

**Remarque :** Si l'on écrit  $U = [\mathbf{u}_1, \dots, \mathbf{u}_n]$  cela signifie que :

$$A = \sum_{i=1}^n \lambda_i \mathbf{u}_i \mathbf{u}_i^T, \quad \text{avec } \forall i \in \{1, \dots, n\}, \quad A \mathbf{u}_i = \lambda_i \mathbf{u}_i$$

### 2.2 La décomposition en valeurs singulières

**Théorème :**

Pour toute matrice  $M \in \mathbb{R}^{m_1 \times m_2}$  et de rang  $r$ , il existe une matrice orthogonale  $U \in \mathbb{R}^{m_1 \times r}$  et une matrice orthogonale  $V \in \mathbb{R}^{m_2 \times r}$ , telles que

$$M = U \text{diag}(s_1, \dots, s_r) V^T$$

avec  $s_1 \geq s_2 \geq \dots \geq s_r \geq 0$  sont les **valeurs singulières** de  $M$ , ou encore :

$$M = \sum_{i=1}^r s_i u_i v_i^T$$

avec  $U = [\mathbf{u}_1, \dots, \mathbf{u}_r]$  et  $V = [\mathbf{v}_1, \dots, \mathbf{v}_r]$ .

**Remarques :**

1- Les matrices sont obtenues comme suit :

(i) les valeurs singulières sont les racines carrées des valeurs propres à la fois de  $M^T M$  et  $MM^T$ .

(ii)  $U$  est la matrice des vecteurs propres de  $M^T M$ .

(iii)  $V$  est la matrice des vecteurs propres de  $MM^T$ .

2 -  $\sum_{i=1}^r s_i u_i v_i^T$  somme des termes de rang 1 ( $rg(u_i, v_i^T) = 1$ ).

3- On peut aussi forcer les  $u_1, \dots, u_r$  à être orthogonaux deux à deux (de même pour les  $v_i$ ), ie :  $U^T U = \mathbf{I}_r$  et  $V^T V = \mathbf{I}_r$ .

4- Les  $\mathbf{u}_i$  (resp. les  $\mathbf{v}_i^T$ ) sont orthonormés et engendrent le même espace que celui engendré par les colonnes (resp. les lignes) de  $M$

$$\text{vect}(\mathbf{m}_1, \dots, \mathbf{m}_{m_2}) = \text{vect}(\mathbf{u}_1, \dots, \mathbf{u}_r)$$

5- SVD généralise aux matrices non carées la décomposition spectrale.

### Preuve :

$M^T M$  est une matrice  $m_2 \times m_2$  symétrique, semi définie positive, et de rang  $r$  ( $rg(M^T M) = rg(M)$ ), donc elle admet des valeurs propres réelles positives ( $\lambda_1, \dots, \lambda_r, \dots$ ) et une base orthonormée de vecteurs propres associés ( $v_1, \dots, v_r, \dots$ ) :

$$M^T M v_i = \lambda_i v_i$$

De plus :

$$v_j^T M^T M v_i = \lambda_i v_j^T v_i = \lambda_i \delta_{ij}$$

Définissons pour tout  $i = 1, \dots, r$  :

$$s_i = \sqrt{\lambda_i} \quad \text{et} \quad u_i = \frac{M v_i}{\sqrt{\lambda_i}}$$

Les  $(u_1, \dots, u_r)$  forment une famille orthonormée, en effet :

$$\langle u_i, u_j \rangle = \left\langle \frac{M v_i}{\sqrt{\lambda_i}}, \frac{M v_j}{\sqrt{\lambda_j}} \right\rangle = \frac{1}{\sqrt{\lambda_i \lambda_j}} \langle M v_i, M v_j \rangle = \frac{\lambda_i}{\sqrt{\lambda_i \lambda_j}} \delta_{ij}.$$

Si  $i \neq j$   $\langle u_i, u_j \rangle = 0$ .

Si  $i = j$   $\langle u_i, u_j \rangle = \frac{\lambda_i}{\sqrt{\lambda_i \lambda_i}} = 1$ .

Alors, pour  $U = [\mathbf{u}_1, \dots, \mathbf{u}_r] \in \mathbb{R}^{m_1 \times r}$  et  $V = [\mathbf{v}_1, \dots, \mathbf{v}_r] \in \mathbb{R}^{m_2 \times r}$ , on a :

$$\begin{aligned} U^T M V &= \begin{pmatrix} \frac{1}{s_1} v_1^T M^T M v_1 & 0 & \dots & 0 \\ 0 & \frac{1}{s_2} v_2^T M^T M v_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \dots & 0 & \frac{1}{s_r} v_r^T M^T M v_r \end{pmatrix} \\ &= \begin{pmatrix} \frac{\lambda_1}{s_1} v_1^T v_1 & 0 & \dots & 0 \\ 0 & \frac{\lambda_2}{s_2} v_2^T v_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \dots & 0 & \frac{\lambda_r}{s_r} v_r^T v_r \end{pmatrix} = \begin{pmatrix} s_1 & 0 & \dots & 0 \\ 0 & s_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \dots & 0 & s_r \end{pmatrix} = \text{diag}(s_1, \dots, s_r). \end{aligned}$$

### Proposition :

$U U^T$  est la projection orthogonale sur l'espace engendré par les  $(\mathbf{u}_1, \dots, \mathbf{u}_r)$ .

### Preuve :

*Rappel :* la projection orthogonale d'un vecteur  $\mathbf{y} \in \mathbb{R}^{m_2}$  sur le sous espace vectoriel de  $\mathbb{R}^{m_2}$  engendré par  $(\mathbf{u}_1, \dots, \mathbf{u}_r)$ . Cette projection, notée  $\mathbb{P}_U$  est caractérisée par les propriétés :

(i)  $\mathbb{P}_U(\mathbf{y})$  est une combinaison linéaire des colonnes de  $U$ .

(ii)  $\mathbf{y} - \mathbb{P}_U(\mathbf{y})$  est orthogonal aux colonnes de  $U$ .

- Commençons à prouver les deux propriétés caractéristique de la projection orthogonale.

(i) Le produit  $U^T \mathbf{y}$  est un vecteur ligne de taille  $r$ . Notons le  $(\mathbf{x}_1, \dots, \mathbf{x}_r)$ . On peut alors écrire le vecteur  $UU^T \mathbf{y}$  de la façon suivante :

$$UU^T \mathbf{y} = \sum_{i=1}^r \mathbf{x}_i \mathbf{u}_i$$

C'est-à-dire que la propriété caractéristique (i) est vérifiée.

(ii) Soit  $\mathbf{w}$  la matrice ligne de taille  $r$  dont les éléments sont les produits scalaires  $\langle \mathbf{y} - UU^T \mathbf{y}, \mathbf{w}_i \rangle$ . On veut montrer que chacun de ces produits scalaires est nul, c'est-à-dire que  $\mathbf{w}$  est le vecteur nul. Or

$$\mathbf{w} = U^T (\mathbf{y} - UU^T \mathbf{y}) = U^T \mathbf{y} - U^T UU^T \mathbf{y} = U^T \mathbf{y} - U^T \mathbf{y} = 0$$

#### Corollaire :

Comme  $\text{vect}(\mathbf{m}_1, \dots, \mathbf{m}_{m_2}) = \text{vect}(\mathbf{u}_1, \dots, \mathbf{u}_r)$  ( d'après la remarque 4 ), On peut déduire que  $UU^T$  est la projection orthogonale sur l'espace engendré par les colonnes de  $M$ . Ainsi  $U^T U M = M$ .

Identiquement, on peut montrer que  $M V V^T = M$ , ceci donne :  $U U^T M V V^T = U U^T M = M$ .

### 3 Pseudo-inverse ( Moore-Penrose (1955), inverse généralisée)

#### Définition :

Si  $X \in \mathbb{R}^{m_1 \times m_2}$ , admet pour SVD  $X = \sum_{i=1}^r s_i \mathbf{u}_i \mathbf{v}_i^T$  avec  $r = \text{rang}(X)$ , alors sa **pseudo-inverse**  $X^+ \in \mathbb{R}^{m_2 \times m_1}$  est définie par :

$$X^+ = \sum_{i=1}^r \frac{1}{s_i} \mathbf{v}_i \mathbf{u}_i^T$$

#### Remarques :

1-  $X^+ X$  et  $X X^+$  existant.

2- Si  $X = \sum_{i=1}^n s_i \mathbf{u}_i \mathbf{v}_i^T \in \mathbb{R}^{m \times m}$  est inversible alors  $X^+ = X^{-1}$ , en effet :

$$\begin{aligned} X X^+ &= \sum_{j=1}^n s_j \mathbf{u}_j \mathbf{v}_j^T \sum_{i=1}^n \frac{1}{s_i} \mathbf{v}_i \mathbf{u}_i^T \\ &= \sum_{j=1}^n \sum_{i=1}^n s_j \frac{1}{s_i} \mathbf{u}_j \mathbf{v}_j^T \mathbf{v}_i \mathbf{u}_i^T \\ &= \sum_{j=1}^n \sum_{i=1}^n s_j \frac{1}{s_i} \delta_{i,j} \mathbf{u}_j \mathbf{u}_i^T = \sum_{i=1}^n \mathbf{u}_i \mathbf{u}_i^T = \text{Id}_n \end{aligned}$$

#### 3.1 SVD et numérique

Les fonctions SVD et pseudo-inverse sont disponibles dans les bibliothèques numériques classiques, par exemple **Numpy**

• SVD :  $U, s, V = \text{np.linalg.svd}(X)$

Attention dans ce cas :  $\mathbf{X} = \mathbf{U}.\text{dot}(\text{np.diag}(s)).\text{dot}(\mathbf{V})$  On accède aux variantes compactes ou non par l'option *cf*.

**full-matrices**=True/False.

• Pseudo-inverse :  $\mathbf{Xinv} = \text{np.linalg.pinv}(X)$ .

#### Exemple :

Soit une matrice A et sa décomposition sigulière obtenu avec la commande

$U, s, V = \text{np.linalg.svd}(A)$

$$A = \begin{bmatrix} 2 & 1 & 6 & 1 \\ 1 & 1 & 1 & 2 \\ 0 & 1 & 2 & 3 \end{bmatrix} \quad U = \begin{bmatrix} 0.863 & 0.505 & -0.002 \\ 0.286 & -0.485 & 0.827 \\ 0.416 & -0.714 & -0.563 \end{bmatrix}$$

$$S = \begin{bmatrix} 7.304 & 0 & 0 & 0 \\ 0 & 2.967 & 0 & 0 \\ 0 & 0 & 0.918 & 0 \end{bmatrix} \quad V = \begin{bmatrix} 0.275 & 0.177 & 0.896 & -0.302 \\ 0.214 & -0.234 & 0.285 & 0.905 \\ 0.862 & 0.376 & -0.339 & 0.000 \\ 0.367 & -0.879 & -0.041 & -0.302 \end{bmatrix}$$

Le pseudo inverse peut être obtenu aussi plus simplement avec la commande  $A^+ = \text{np.linalg.pinv}(A)$

$$A^+ = \begin{bmatrix} 0.061 & 0.788 & -0.576 \\ -0.015 & 0.303 & -0.106 \\ 0.167 & -0.333 & 0.167 \\ -0.106 & 0.121 & 0.258 \end{bmatrix}$$

## Références

- [1] SVD, Nicolas Verzelen, Joseph Salmon, INRA / Université de Montpellier.
- [2] METHODES NUMERIQUES, Manfred GILLI.
- [3] La Décomposition en Valeurs Singulières, Analyse numérique et Application à la Vision, Valérie Perrier, Roger Mohr, Ensimag et Laboratoire Jean Kuntzmann.
- [4] Cours de Mathématiques II, Chapitre 1. Algèbre linéaire, Université de Paris X Nanterre, U.F.R. Segmi.