

2019

# Algèbre linéaire pour les statistiques

Joseph Salmon  
Université de Montpellier



## Préface

# Table des matières

<b>I</b>	<b>Rappels</b>	<b>4</b>
<b>1</b>	<b>Matrices classiques</b>	<b>5</b>
1.1	Matrice orthogonale . . . . .	5
1.2	Matrice $J_n$ et recentrage . . . . .	5
1.3	Matrices stochastiques, doublement stochastiques . . . . .	7
<b>2</b>	<b>Inversion de matrices</b>	<b>8</b>
2.1	Inversion des matrices par blocs . . . . .	8
<b>3</b>	<b>Décompositions classiques</b>	<b>11</b>
3.1	Décomposition spectrale . . . . .	11
3.2	Décomposition en valeurs singulières (SVD) . . . . .	11
<b>II</b>	<b>Outils pour l'ANOVA</b>	<b>12</b>
<b>4</b>	<b>Matrice pour l'analyse de la variance</b>	<b>13</b>
4.1	Moindres carrées et contraintes . . . . .	14
<b>5</b>	<b>Produit de Kronecker</b>	<b>17</b>
5.1	Introduction et propriétés . . . . .	17

## **Première partie**

### **Rappels**

# 1

## Matrices classiques

### 1.1 Matrice orthogonale

**Définition 1.1.** Une matrice  $U \in \mathbb{R}^{n \times n}$  est dite orthogonale si elle vérifie la propriété suivante

$$U^\top U = UU^\top = \text{Id}_n . \quad (1.1)$$

Une telle matrice  $U$  peut s'écrire en colonne  $U = [u_1, \dots, u_n]$  et ses colonnes satisfont les relations

$$\forall i \in \llbracket 1, n \rrbracket, u_i^\top u_j = \delta_{ij} , \quad (1.2)$$

où le symbole de Kronecker  $\delta$  est défini pour tout  $(i, j) \in \llbracket 1, n \rrbracket$  par

$$\delta_{ij} = \begin{cases} 1, & \text{si } i = j, \\ 0, & \text{si } i \neq j. \end{cases} \quad (1.3)$$

Ainsi les vecteurs  $u_1, \dots, u_n$  forment une base orthonormale.

### 1.2 Matrice $J_n$ et recentrage

Soit  $\mathbb{1}_n \in \mathbb{R}^n$  le vecteur de taille  $n$  ne contenant que des 1. On définit alors la matrice  $J_n$  par

$$J_n = \mathbb{1}_n \mathbb{1}_n^\top \in \mathbb{R}^n . \quad (1.4)$$

**Propriétés :** La matrice  $J_n$  est symétrique définie positive :

$$J_n^2 = nJ_n . \quad (1.5)$$

On associe souvent aussi le projecteur :  $\bar{J}_n$  défini par  $\bar{J}_n = \frac{1}{n}J_n$ . Le projecteur orthogonal associé  $\bar{C}_n = \text{Id}_n - \bar{J}_n$  est la matrice que l'on appelle la *matrice de centrage* car pour tout vecteur  $x \in \mathbb{R}^n$  on observe que

$$\bar{C}_n x = (x_1 - \bar{x}_n, \dots, x_n - \bar{x}_n) . \quad (1.6)$$

Décomposition spectrale :

$$J_n = H_n^\top \text{diag}(n, 0, \dots, 0) H_n \quad (1.7)$$

$$\bar{J}_n = H_n^\top \text{diag}(1, 0, \dots, 0) H_n . \quad (1.8)$$

où  $H_n \in \mathbb{R}^{n \times n}$  est la matrice de Helmert, c'est-à-dire la matrice orthogonale définie par :

$$H_n = \begin{bmatrix} \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \dots & \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} \\ \frac{1}{\sqrt{n}} & \frac{-1}{\sqrt{n}} & 0 & 0 & \dots & 0 & 0 \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{6}} & \frac{-2}{\sqrt{6}} & 0 & \dots & 0 & 0 \\ \frac{1}{\sqrt{12}} & \frac{1}{\sqrt{12}} & \frac{1}{\sqrt{12}} & \frac{-3}{\sqrt{12}} & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \dots & \frac{1}{\sqrt{n(n-1)}} & \frac{-(n-1)}{\sqrt{n(n-1)}} \end{bmatrix} .$$

**Propriétés :** Pour tout  $(a, b, a', b') \in \mathbb{R}^4$ , on a

$$(a \text{Id}_n + b J_n)(a' \text{Id}_n + b' J_n) = aa' \text{Id}_n + (ab' + a'b + nb b') J_n, \quad (1.9)$$

$$(a \text{Id}_n + b J_n)^{-1} = \frac{1}{a} \left( \text{Id}_n - \frac{b}{a + nb} J_n \right), \quad \text{pour } a \neq 0 \text{ et } a \neq -nb, \quad (1.10)$$

$$a \text{Id}_n + b J_n = H_n^\top \text{diag}(a + nb, \underbrace{a, \dots, a}_{(n-1) \text{ fois}}) H_n, \quad (\text{décomp. spectrale}) \quad (1.11)$$

$$\det(a \text{Id}_n + b J_n) = a^{n-1} (a + nb) \quad (1.12)$$

**Exemple 1.2.** Prenons un modèle à effet aléatoire pour une catégorie à  $K$  modalités  $C_1, \dots, C_K$  et  $n$  observations (avec  $n = n_1 + \dots + n_K$ ) :

$$y = \mu \mathbb{1}_n + \sum_{k=1}^K \mathbb{1}_{C_k} a_k + \varepsilon . \quad (1.13)$$

avec  $\varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2 \text{Id}_n)$  et  $a \sim \mathcal{N}(0, \sigma_a^2 \text{Id}_K)$ . Dans ce cas la matrice de covariance de  $y \in \mathbb{R}^n$

s'écrit :

$$\text{Var}(y) = \text{Var}(\varepsilon) + \text{Var}(\begin{bmatrix} \mathbb{1}_{C_1} & \cdots & \mathbb{1}_{C_K} \end{bmatrix} a) \quad (1.14)$$

$$= \sigma_\varepsilon^2 \text{Id}_n + \begin{bmatrix} \mathbb{1}_{C_1} & \cdots & \mathbb{1}_{C_K} \end{bmatrix} \text{Var}(aa^\top) \begin{bmatrix} \mathbb{1}_{C_1} & \cdots & \mathbb{1}_{C_K} \end{bmatrix}^\top \quad (1.15)$$

$$= \sigma_\varepsilon^2 \text{Id}_n + \begin{bmatrix} \mathbb{1}_{C_1} & \cdots & \mathbb{1}_{C_K} \end{bmatrix} \sigma_a^2 \text{Id}_K \begin{bmatrix} \mathbb{1}_{C_1} & \cdots & \mathbb{1}_{C_K} \end{bmatrix}^\top \quad (1.16)$$

$$\text{Var}(y) = \sigma_\varepsilon^2 \text{Id}_n + \sigma_a^2 \begin{bmatrix} J_{n_1} & 0 & \cdots & \cdots & 0 \\ 0 & J_{n_2} & \ddots & & \vdots \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ \vdots & & \ddots & J_{n_{K-1}} & 0 \\ 0 & \cdots & \cdots & 0 & J_{n_K} \end{bmatrix} \quad (1.17)$$

$$\text{Var}(y) = \begin{bmatrix} \sigma_\varepsilon^2 \text{Id}_{n_1} + \sigma_a^2 J_{n_1} & 0 & \cdots & \cdots & 0 \\ 0 & \sigma_\varepsilon^2 \text{Id}_{n_2} + \sigma_a^2 J_{n_2} & \ddots & & \vdots \\ \vdots & & \ddots & \ddots & \vdots \\ \vdots & & & \sigma_\varepsilon^2 \text{Id}_{n_{K-1}} + \sigma_a^2 J_{n_{K-1}} & 0 \\ 0 & \cdots & \cdots & 0 & \sigma_\varepsilon^2 \text{Id}_{n_K} + \sigma_a^2 J_{n_K} \end{bmatrix} \quad (1.18)$$

On peut donc en déduire avec Eq. (1.10)

$$(\text{Var}(y))^{-1} = \begin{bmatrix} \frac{1}{\sigma_\varepsilon^2} \left( \text{Id}_{n_1} - \frac{\sigma_a^2}{\sigma_\varepsilon^2 + n_1 \sigma_a^2} J_{n_1} \right) & 0 & \cdots & \cdots & 0 \\ 0 & \ddots & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & 0 \\ 0 & \cdots & \cdots & 0 & \frac{1}{\sigma_\varepsilon^2} \left( \text{Id}_{n_K} - \frac{\sigma_a^2}{\sigma_\varepsilon^2 + n_K \sigma_a^2} J_{n_K} \right) \end{bmatrix} \quad (1.19)$$

### 1.3 Matrices stochastiques, doublement stochastiques

SENETA (*Non-negative matrices and Markov chains*)

BHATIA (*Matrix analysis*)

# 2

## Inversion de matrices

### 2.1 Inversion des matrices par blocs

Pour toutes matrices  $A \in \mathbb{R}^{n_1 \times n_1}$ ,  $B \in \mathbb{R}^{n_1 \times n_2}$ ,  $C \in \mathbb{R}^{n_2 \times n_1}$ ,  $D \in \mathbb{R}^{n_2 \times n_2}$  telles que les matrices  $\begin{bmatrix} A & B \\ C & D \end{bmatrix}$ ,  $A$  et  $D$  sont inversibles on a les relations suivantes :

$$\begin{aligned} \begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} &= \begin{bmatrix} A^{-1} + A^{-1}B(D - CA^{-1}B)^{-1}CA^{-1} & -A^{-1}B(D - CA^{-1}B)^{-1} \\ -(D - CA^{-1}B)^{-1}CA^{-1} & (D - CA^{-1}B)^{-1} \end{bmatrix} \\ &= \begin{bmatrix} (A - BD^{-1}C)^{-1} & -(A - BD^{-1}C)^{-1}BD^{-1} \\ -D^{-1}C(A - BD^{-1}C)^{-1} & D^{-1}C(A - BD^{-1}C)^{-1}BD^{-1} + D^{-1} \end{bmatrix} . \end{aligned}$$

Conséquence : les déterminants suivants sont égaux :

$$\left| \begin{bmatrix} A & B \\ C & D \end{bmatrix} \right| = |A||D - CA^{-1}B| = |D||A - BD^{-1}C| .$$

De plus si  $AC = CA$  monter qu'alors  $\left| \begin{bmatrix} A & B \\ C & D \end{bmatrix} \right| = |AD - CB|$ .

Identité de Woodbury sous les mêmes hypothèses :

$$(A + BDC)^{-1} = A^{-1} - A^{-1}B(D^{-1} + CA^{-1}B)^{-1}CA^{-1} . \quad (2.1)$$

La formule précédente donne la relation suivante pour des scalaires  $x \neq 0$  et  $\delta \neq 0$  :

$$\frac{1}{x + \delta} = \frac{1}{x} - \left( \frac{1}{x} \right)^2 \cdot \left( \frac{1}{\delta} + \frac{1}{x} \right)^{-1} . \quad (2.2)$$

Enfin relation suivante pour des vecteurs  $u \in \mathbb{R}^{n_1}$  et  $v \in \mathbb{R}^{n_1}$  :

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u} . \quad (2.3)$$



Rem: On appelle complément de Schur du bloc  $D$  de la matrice  $M$ , la matrice de dimension  $n_1 \times n_2$  suivante :  $A - BD^{-1}C$ , qu'on note parfois  $M/D$ .

*Démonstration.* Premier point : commençons par appliquer un premier pivot (par bloc) sur notre matrice, en éliminant la matrice “ $C$ ” en bas à gauche :

$$\begin{bmatrix} I_{n_1} & 0 \\ -CA^{-1} & I_{n_2} \end{bmatrix} \begin{bmatrix} A & B \\ C & D \end{bmatrix} = \begin{bmatrix} A & B \\ 0 & D - CA^{-1}B \end{bmatrix} .$$

On élimine de la même manière le bloc en haut à droite :

$$\begin{bmatrix} I_{n_1} & 0 \\ -CA^{-1} & I_{n_2} \end{bmatrix} \begin{bmatrix} A & B \\ C & D \end{bmatrix} \begin{bmatrix} I_{n_1} & -A^{-1}B \\ 0 & I_{n_2} \end{bmatrix} = \begin{bmatrix} A & B \\ 0 & D - CA^{-1}B \end{bmatrix} \begin{bmatrix} I_{n_1} & -A^{-1}B \\ 0 & I_{n_2} \end{bmatrix} = \begin{bmatrix} A & 0 \\ 0 & D - CA^{-1}B \end{bmatrix} .$$

Remarquons alors que l'on peut facilement inverser les matrices triangulaires par blocs :

$$\begin{bmatrix} I_{n_1} & A^{-1}B \\ 0 & I_{n_2} \end{bmatrix} \begin{bmatrix} I_{n_1} & -A^{-1}B \\ 0 & I_{n_2} \end{bmatrix} = I_{n_1+n_2} \\ \begin{bmatrix} I_{n_1} & 0 \\ CA^{-1} & I_{n_2} \end{bmatrix} \begin{bmatrix} I_{n_1} & 0 \\ -CA^{-1} & I_{n_2} \end{bmatrix} = I_{n_1+n_2} .$$

Ainsi en inversant les matrices diagonales, on obtient la factorisation LDU (Low triangular, Diagonal, Upper triangular)

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} = \begin{bmatrix} I_{n_1} & 0 \\ CA^{-1} & I_{n_2} \end{bmatrix} \begin{bmatrix} A & 0 \\ 0 & D - CA^{-1}B \end{bmatrix} \begin{bmatrix} I_{n_1} & A^{-1}B \\ 0 & I_{n_2} \end{bmatrix} . \quad (2.4)$$

En inversant les deux côtés :

$$\begin{aligned} \begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} &= \begin{bmatrix} I_{n_1} & A^{-1}B \\ 0 & I_{n_2} \end{bmatrix}^{-1} \begin{bmatrix} A & 0 \\ 0 & D - CA^{-1}B \end{bmatrix}^{-1} \begin{bmatrix} I_{n_1} & 0 \\ CA^{-1} & I_{n_2} \end{bmatrix}^{-1} \\ &= \begin{bmatrix} I_{n_1} & -A^{-1}B \\ 0 & I_{n_2} \end{bmatrix} \begin{bmatrix} A^{-1} & 0 \\ 0 & (D - CA^{-1}B)^{-1} \end{bmatrix} \begin{bmatrix} I_{n_1} & 0 \\ -CA^{-1} & I_{n_2} \end{bmatrix} \\ &= \begin{bmatrix} A^{-1} & -A^{-1}B(D - CA^{-1}B)^{-1} \\ 0 & (D - CA^{-1}B)^{-1} \end{bmatrix} \begin{bmatrix} I_{n_1} & 0 \\ -CA^{-1} & I_{n_2} \end{bmatrix} \\ &= \begin{bmatrix} A^{-1} + A^{-1}B(D - CA^{-1}B)^{-1}CA^{-1} & -A^{-1}B(D - CA^{-1}B)^{-1} \\ -(D - CA^{-1}B)^{-1}CA^{-1} & (D - CA^{-1}B)^{-1} \end{bmatrix} . \end{aligned} \quad (2.5)$$

On procède de même pour la seconde relation et on obtient la factorisation UDL (Upper triangular, Diagonal, Lower Triangular) :

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} = \begin{bmatrix} I_{n_1} & BD^{-1} \\ 0 & I_{n_2} \end{bmatrix} \begin{bmatrix} A - BD^{-1}C & 0 \\ 0 & D \end{bmatrix} \begin{bmatrix} I_{n_1} & 0 \\ D^{-1}C & I_{n_2} \end{bmatrix} . \quad (2.6)$$

De nouveau on peut inverser les deux membres :

$$\begin{aligned} \begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} &= \begin{bmatrix} I_{n_1} & 0 \\ D^{-1}C & I_{n_2} \end{bmatrix}^{-1} \begin{bmatrix} A - BD^{-1}C & 0 \\ 0 & D \end{bmatrix}^{-1} \begin{bmatrix} I_{n_1} & BD^{-1} \\ 0 & I_{n_2} \end{bmatrix}^{-1} \\ &= \begin{bmatrix} I_{n_1} & 0 \\ -D^{-1}C & I_{n_2} \end{bmatrix} \begin{bmatrix} (A - BD^{-1}C)^{-1} & 0 \\ 0 & D^{-1} \end{bmatrix} \begin{bmatrix} I_{n_1} & -BD^{-1} \\ 0 & I_{n_2} \end{bmatrix} \\ &= \begin{bmatrix} (A - BD^{-1}C)^{-1} & -(A - BD^{-1}C)^{-1}BD^{-1} \\ -D^{-1}C(A - BD^{-1}C)^{-1} & D^{-1}C(A - BD^{-1}C)^{-1}BD^{-1} + D^{-1} \end{bmatrix} . \end{aligned} \quad (2.7)$$

Second point : il suffit de calculer les déterminants dans les relations données par les Équations (2.4) et (2.6).  $\square$

# 3

## Décompositions classiques

### 3.1 Décomposition spectrale

HORN et JOHNSON (*Topics in matrix analysis*)

GOLUB et VAN LOAN (*Matrix computations*)

STRANG (*Introduction to linear algebra*)

#### 3.1.1 Valeurs propres du laplacien sur graphe

<http://www.math.ucsd.edu/~fan/research/cb/ch1.pdf>

### 3.2 Décomposition en valeurs singulières (SVD)

**Deuxième partie**

**Outils pour l'ANOVA**

# 4

## Matrice pour l'analyse de la variance

Plan d'expériences : on observe  $K$  classes  $C_1, \dots, C_K$  (e.g., les variétés de blé sur une parcelle) et  $n$  observations d'un phénomène (e.g., le rendement de la variété) sont considérées. On fait l'hypothèse que les classes  $C_k$  sont disjointes et forment une partition des observations :  $\cup_{k=1}^K C_k = \llbracket 1, n \rrbracket$  et  $\forall (k, k') \in \llbracket 1, K \rrbracket, C_k \cap C_{k'} = \emptyset$ . On appelle cet encodage l'encodage “un-chaud” (🇬🇧 : *one-hot*) ou par variable indicatrice, ou encore par variable factice (🇬🇧 : *dummy variable*). Enfin on suppose que la cardinalité de chaque classe  $C_k$  est  $n_k$ , et donc que  $n = \sum_{k=1}^K n_k$ .

Le modèle de l'ANOVA peut alors s'écrire, sous l'hypothèse gaussienne que pour tout  $i \in \llbracket 1, n \rrbracket, \varepsilon_i \stackrel{i.i.d.}{\sim} \mathcal{N}(0, \sigma^2)$  et pour tout  $(i, k) \in \llbracket 1, n \rrbracket \times \llbracket 1, K \rrbracket$ ,

$$y_i = \mu + a_k \delta_{i, C_k} + \varepsilon_i \quad (4.1)$$

$$\text{où } \delta_{i, C_k} = \begin{cases} 1, & \text{si } i \in C_k \\ 0, & \text{si } i \notin C_k \end{cases}.$$

Interprétation : les  $a_k$  sont les coefficients qui correspondent au niveau d'influence de la  $k^{\text{e}}$  classe

$$y = \underbrace{\begin{bmatrix} \mathbb{1}_n & \mathbb{1}_{C_1} & \dots & \mathbb{1}_{C_K} \end{bmatrix}}_X \underbrace{\begin{bmatrix} \mu \\ a_1 \\ \vdots \\ a_K \end{bmatrix}}_{\beta} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_K \end{bmatrix}. \quad (4.2)$$

**Remarque 4.1.** La matrice  $X \in \mathbb{R}^{n \times K+1}$  est de rang  $K$  car  $\mathbb{1}_n = \sum_{k=1}^K \mathbb{1}_{C_k}$  et les vecteurs  $\mathbb{1}_{C_1}, \dots, \mathbb{1}_{C_K}$  sont linéairement indépendants et générateurs (cela est vrai car les classes  $C_k$  sont disjointes et forment une partition de l'espace :  $\cup_{k=1}^K C_k = \llbracket 1, n \rrbracket$ ). Ainsi on ne peut pas appliquer la formule  $(X^\top X)^{-1} X^\top y$  pour obtenir une solution des moindres carrés : en effet  $\text{rg}(X) = \text{rg}(X^\top X) = K < K + 1$  mais  $X^\top X \in \mathbb{R}^{(K+1) \times (K+1)}$ .

On peut expliciter la matrice de Gram  $X^\top X$  dans ce contexte :

$$X^\top X = \begin{bmatrix} n & n_1 & \cdots & \cdots & n_K \\ n_1 & n_1 & 0 & \cdots & 0 \\ \vdots & 0 & \ddots & \ddots & \vdots \\ \vdots & \vdots & \ddots & n_{K-1} & 0 \\ n_K & 0 & \cdots & 0 & n_K \end{bmatrix} .$$

#### 4.1 Moindres carrées et contraintes

On cherche pour l'estimation des moindres carrés à résoudre le problème suivant, avec des contraintes sur les  $a_k$ , ce qui correspond à

$$\min_{\beta \in \mathbb{R}^{K+1}} \frac{1}{2} \|y - X\beta\|^2 , \quad (4.3)$$

$$\text{t.q. } \beta = (\mu, a_1, \dots, a_K)^\top \text{ et } \sum_{k=1}^K c_k a_k = 0 , \quad (4.4)$$

où le vecteur  $c = (c_1, \dots, c_K)^\top \in \mathbb{R}^K$  est un vecteur encodant les contraintes choisies telles que  $\sum_{k=1}^K c_k \neq 0$ . On distingue trois types de contraintes :

1. Le cas où l'on choisit une classe  $C_{k_0}$  comme référence. Cela revient à prendre  $c = (0, \dots, \underbrace{1}_{\text{en } k_0^{\text{e}} \text{ position}}, \dots, 0)$ , ce qui revient à la contrainte " $a_{k_0} = 0$ ".
2. Le cas où l'on choisit des contributions des classes centrées autour de la moyenne  $c = (1, \dots, 1)$ , ce qui revient à la contrainte  $\sum_{k=1}^K a_k = 0$ .
3. Le cas où l'on choisit des contributions pondérées des classes centrées autour de la moyenne pondérée  $c = (n_1, \dots, n_K)$ , ce qui revient à la contrainte  $\sum_{k=1}^K n_k a_k = 0$ .

Formation du Lagrangien :

$$\mathcal{L}(\beta, \gamma) = \frac{1}{2} \|y - X\beta\|^2 + \gamma a^\top c . \quad (4.5)$$

Condition nécessaire du premier ordre :

$$\frac{\partial \mathcal{L}(\beta, \gamma)}{\partial \beta} = 0 \iff X^\top (X\beta - y) + \gamma c = 0 \quad (4.6)$$

$$\iff X^\top X\beta + \gamma c = X^\top y \quad (4.7)$$

$$\iff \begin{bmatrix} n & n_1 & \cdots & \cdots & n_K & 0 \\ n_1 & n_1 & 0 & \cdots & 0 & c_1 \\ \vdots & 0 & \ddots & \ddots & \vdots & \vdots \\ \vdots & \vdots & \ddots & n_{K-1} & 0 & c_{K-1} \\ n_K & 0 & \cdots & 0 & n_K & c_K \\ 0 & c_1 & \cdots & c_{K-1} & c_K & 0 \end{bmatrix} \begin{bmatrix} \beta \\ \gamma \end{bmatrix} = \begin{bmatrix} X^\top y \\ 0 \end{bmatrix} . \quad (4.8)$$

Tout d'abord il est facile de vérifier que  $X^\top y = \begin{bmatrix} n\bar{y}_n \\ n_1\bar{y}_{C_1} \\ \vdots \\ n_K\bar{y}_{C_K} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i \in C_1} y_i \\ \vdots \\ \sum_{i \in C_K} y_i \end{bmatrix}$  avec la notation

$\bar{y}_{C_k} = \frac{1}{n_k} \sum_{i \in C_k} y_i$  pour tout  $k \in \llbracket 1, K \rrbracket$ .

En multipliant à gauche par la matrice  $\text{diag}(\frac{1}{n}, \frac{1}{n_1}, \dots, \frac{1}{n_K}, 1)$  le système précédent on obtient :

$$\begin{bmatrix} 1 & \frac{n_1}{n} & \cdots & \cdots & \frac{n_K}{n} & 0 \\ 1 & 1 & 0 & \cdots & 0 & \frac{c_1}{n_1} \\ \vdots & 0 & \ddots & \ddots & \vdots & \vdots \\ \vdots & \vdots & \ddots & 1 & 0 & \frac{c_{K-1}}{n_{K-1}} \\ 1 & 0 & \cdots & 0 & 1 & \frac{c_K}{n_K} \\ 0 & c_1 & \cdots & c_{K-1} & c_K & 0 \end{bmatrix} \begin{bmatrix} \mu \\ a \\ \gamma \end{bmatrix} = \begin{bmatrix} \bar{y}_n \\ \bar{y}_{C_1} \\ \vdots \\ \bar{y}_{C_K} \\ 0 \end{bmatrix}. \quad (4.9)$$

En prenant les équations de la ligne 2 à  $K + 1$ , on en déduit les équations suivantes :

$$\begin{cases} \hat{a}_K = \bar{y}_{C_K} - \hat{\mu} - \frac{c_K}{n_K} \gamma \\ \vdots \\ \hat{a}_k = \bar{y}_{C_k} - \hat{\mu} - \frac{c_k}{n_k} \gamma \\ \vdots \\ \hat{a}_1 = \bar{y}_{C_1} - \hat{\mu} - \frac{c_1}{n_1} \gamma \end{cases} \quad (4.10)$$

Avec la première équation du système précédent, i.e.,

$$\hat{\mu} + \sum_{k=1}^K \frac{n_k}{n} a_k = \bar{y}_n \quad (4.11)$$

et en sommant avec les poids du système d'équation précédent, on obtient :

$$\sum_{k=1}^K \frac{n_k}{n} \hat{a}_k = \sum_{k=1}^K \frac{n_k}{n} \bar{y}_{C_k} - \hat{\mu} + \frac{\gamma}{n} \sum_{k=1}^K c_k \quad (4.12)$$

ce qui implique que

$$\frac{\gamma}{n} \sum_{k=1}^K c_k = 0. \quad (4.13)$$

Rappelant la condition  $\sum_{k=1}^K c_k \neq 0$ , on en déduit que  $\gamma = 0$ .

Enfin, en sommant avec les poids  $c_K, \dots, c_k, \dots, c_1$  les système d'équations dans (4.10), on obtient :

$$\begin{aligned} 0 &= \sum_{k=1}^K c_k \hat{a}_k = \sum_{k=1}^K c_k \bar{y}_{C_k} - \sum_{k=1}^K c_k \hat{\mu} - \sum_{k=1}^K \frac{c_k^2}{n_K} \gamma = \sum_{k=1}^K c_k \bar{y}_{C_k} - \sum_{k=1}^K c_k \hat{\mu} \\ \iff \hat{\mu} &= \frac{\sum_{k=1}^K c_k \bar{y}_{C_k}}{\sum_{k=1}^K c_k} \end{aligned}$$

On obtient donc comme solution du système initial

$$\left\{ \begin{array}{lcl} \hat{\mu} & = & \frac{\sum_{k=1}^K c_k \bar{y}_{C_K}}{\sum_{k=1}^K c_k} \\ \hat{a}_1 & = & \bar{y}_{C_1} - \hat{\mu} \\ \vdots & & \\ \hat{a}_k & = & \bar{y}_{C_k} - \hat{\mu} \\ \vdots & & \\ \hat{a}_K & = & \bar{y}_{C_K} - \hat{\mu} \end{array} \right. \quad (4.14)$$

On peut maintenant retourner sur les trois cas possibles :

1.  $c = (0, \dots, \underbrace{1}_{\text{en } k_0^{\text{e}} \text{ position}}, \dots, 0) :$

$$\left\{ \begin{array}{lcl} \hat{\mu} & = & \bar{y}_{C_{k_0}} \quad (\text{moyenne de la modalité de référence}) \\ \hat{a}_1 & = & \bar{y}_{C_1} - \bar{y}_{C_{k_0}} \\ \vdots & & \\ \hat{a}_k & = & 0 \\ \vdots & & \\ \hat{a}_K & = & \bar{y}_{C_K} - \bar{y}_{C_{k_0}} \end{array} \right. \quad (4.15)$$

2. Le cas où  $c = (1, \dots, 1) :$

$$\left\{ \begin{array}{lcl} \hat{\mu} & = & \frac{1}{K} \sum_{k=1}^K \bar{y}_{C_K} \quad (\text{moyenne des moyennes par classes}) \\ \hat{a}_1 & = & \bar{y}_{C_1} - \hat{\mu} \\ \vdots & & \\ \hat{a}_k & = & \bar{y}_{C_k} - \hat{\mu} \\ \vdots & & \\ \hat{a}_K & = & \bar{y}_{C_K} - \hat{\mu} \end{array} \right. \quad (4.16)$$

3. Le cas où  $c = (n_1, \dots, n_K) :$

$$\left\{ \begin{array}{lcl} \hat{\mu} & = & \bar{y}_n \quad (\text{moyenne des observations}) \\ \hat{a}_1 & = & \bar{y}_{C_1} - \hat{\mu} \\ \vdots & & \\ \hat{a}_k & = & \bar{y}_{C_k} - \hat{\mu} \\ \vdots & & \\ \hat{a}_K & = & \bar{y}_{C_K} - \hat{\mu} \end{array} \right. \quad (4.17)$$

**Exercice 4.1.** Calculer les conditionnements et choisir numériquement la meilleure contrainte possible.



# 5

## Produit de Kronecker

### 5.1 Introduction et propriétés

**Définition 5.1.** Soient  $A \in \mathbb{R}^{m \times n}$  et  $B \in \mathbb{R}^{p \times q}$ . Leur produit tensoriel ou produit de Kronecker est la matrice  $A \otimes B \in \mathbb{R}^{mp \times nq}$ , définie par blocs successifs de taille  $p \times q$ , le bloc d'indice  $i, j$  valant  $a_{ij}B$ , ou de manière équivalente :

$$A \otimes B = \begin{bmatrix} a_{1,1}B & \cdots & a_{1,n}B \\ \vdots & \ddots & \vdots \\ a_{m,1}B & \cdots & a_{m,n}B \end{bmatrix} \quad (5.1)$$

ou encore

$$A \otimes B = \begin{bmatrix} a_{1,1}b_{1,1} & a_{1,1}b_{1,2} & \cdots & a_{1,1}b_{1,q} & \cdots & \cdots & a_{1,n}b_{1,1} & a_{1,n}b_{1,2} & \cdots & a_{1,n}b_{1,q} \\ a_{1,1}b_{2,1} & a_{1,1}b_{2,2} & \cdots & a_{1,1}b_{2,q} & \cdots & \cdots & a_{1,n}b_{2,1} & a_{1,n}b_{2,2} & \cdots & a_{1,n}b_{2,q} \\ \vdots & \vdots & \ddots & \vdots & & & \vdots & \vdots & \ddots & \vdots \\ a_{1,1}b_{p,1} & a_{1,1}b_{p,2} & \cdots & a_{1,1}b_{p,q} & \cdots & \cdots & a_{1,n}b_{p,1} & a_{1,n}b_{p,2} & \cdots & a_{1,n}b_{p,q} \\ \vdots & \vdots & & \vdots & \ddots & & \vdots & \vdots & & \vdots \\ \vdots & \vdots & & \vdots & & \ddots & \vdots & \vdots & & \vdots \\ a_{m,1}b_{1,1} & a_{m,1}b_{1,2} & \cdots & a_{m,1}b_{1,q} & \cdots & \cdots & a_{m,n}b_{1,1} & a_{m,n}b_{1,2} & \cdots & a_{m,n}b_{1,q} \\ a_{m,1}b_{2,1} & a_{m,1}b_{2,2} & \cdots & a_{m,1}b_{2,q} & \cdots & \cdots & a_{m,n}b_{2,1} & a_{m,n}b_{2,2} & \cdots & a_{m,n}b_{2,q} \\ \vdots & \vdots & \ddots & \vdots & & & \vdots & \vdots & \ddots & \vdots \\ a_{m,1}b_{p,1} & a_{m,1}b_{p,2} & \cdots & a_{m,1}b_{p,q} & \cdots & \cdots & a_{m,n}b_{p,1} & a_{m,n}b_{p,2} & \cdots & a_{m,n}b_{p,q} \end{bmatrix}. \quad (5.2)$$

**Propriétés et liens avec les opérations usuelles :** Prenons  $A, B, C$  et  $D$  quatre matrices quelconques. Alors les relations suivantes sont satisfaites :

$$A \otimes (B + C) = A \otimes B + A \otimes C, \quad (5.3)$$

$$(B + C) \otimes A = B \otimes A + C \otimes A, \quad (5.4)$$

$$(\lambda A) \otimes B = A \otimes (\lambda B) = \lambda(A \otimes B) \quad (\text{pour } \lambda \in \mathbb{R}), \quad (5.5)$$

$$(A \otimes B) \otimes C = A \otimes (B \otimes C), \quad (5.6)$$

$$A \otimes 0 = 0 \otimes A = 0, \quad (5.7)$$

$$(A \otimes B)(C \otimes D) = (AC) \otimes (BD) \quad (\text{quand } AC \text{ et } BD \text{ existent}), \quad (5.8)$$

$$(A \otimes B)^\top = (A^\top \otimes B^\top), \quad (5.9)$$

$$\begin{bmatrix} A_1 & A_2 \end{bmatrix} \otimes B = \begin{bmatrix} A_1 \otimes B & A_2 \otimes B \end{bmatrix} \quad (\text{pour des matrices concaténées}), \quad (5.10)$$

$$(A \otimes B)^{-1} = A^{-1} \otimes B^{-1} \quad (\text{pour } A \text{ et } B \text{ inversibles}). \quad (5.11)$$

**Propriétés spectrales** Prenons des éléments spectraux des matrices  $A \in \mathbb{R}^{n \times n}$  et  $B \in \mathbb{R}^{m \times m}$ , i.e.,  $Ax = ax$  et  $By = \beta y$ , alors

$$(A \otimes B)(x \otimes y) = a\beta(x \otimes y) . \quad (5.12)$$

et par conséquent si l'on prend  $\{a_1, \dots, a_n\}, \{x_1, \dots, x_n\}$  et  $\{\beta_1, \dots, \beta_m\}, \{y_1, \dots, y_m\}$  les couples valeurs/vecteurs propres des matrices  $A$  et  $B$ , alors la matrice  $A \otimes B$  a pour éléments propres  $\{a_i\beta_j, i = 1, \dots, n, j = 1, \dots, m\}$  et  $\{x_i y_j, i = 1, \dots, n, j = 1, \dots, m\}$ . Ainsi

$$\text{tr}(A \otimes B) = \text{tr}(A) \text{tr}(B), \quad (5.13)$$

$$\det(A \otimes B) = \det(A)^m \det(B)^n, \quad (5.14)$$

$$\text{rg}(A \otimes B) = \text{rg}(A) \text{rg}(B). \quad (5.15)$$

## References

CLARKE (*Linear models : the theory and application of analysis of variance*)

SEARLE, CASELLA et McCULLOCH (*Variance components*)

## *Bibliographie*

- BHATIA, R. *Matrix analysis*. T. 169. Graduate Texts in Mathematics. New York : Springer-Verlag, 1997 (p. 7).
- CLARKE, B. R. *Linear models : the theory and application of analysis of variance*. T. 634. John Wiley & Sons, 2008 (p. 18).
- GOLUB, G. H. et C. F. VAN LOAN. *Matrix computations*. Fourth. Johns Hopkins University Press, Baltimore, MD, 2013, p. xiv+756 (p. 11).
- HORN, R. A. et C. R. JOHNSON. *Topics in matrix analysis*. Corrected reprint of the 1991 original. Cambridge : Cambridge University Press, 1994, p. viii+607 (p. 11).
- SEARLE, S. R., G. CASELLA et C. E. MCCULLOCH. *Variance components*. T. 391. John Wiley & Sons, 2009 (p. 18).
- SENETA, E. *Non-negative matrices and Markov chains*. Springer Series in Statistics. New York : Springer, 2006, p. xvi+287 (p. 7).
- STRANG, G. *Introduction to linear algebra*. 5th edition. Wellesley, MA : Wellesley-Cambridge Press, 2016, p. x + 574 (p. 11).