

2019

Algèbre linéaire pour les statistiques

Joseph Salmon
Université de Montpellier



Préface

Table des matières

I	Rappels	4
1	Matrices classiques	5
1.1	Matrice orthogonale	5
1.2	Matrice J_n et recentrage	5
1.3	Matrice stochastique, doublement stochastiques	7
2	Inversion de matrices	8
2.1	Inversion des matrices par blocs	8
3	Décompositions classiques	11
3.1	Décomposition spectrale	11
3.2	Décomposition en valeur singulière (SVD)	11
II	Outils pour l'ANOVA	12
4	Matrice pour l'analyse de la variance	13
4.1	Moindres carrées et contraintes	14
5	Produit de Kronecker	17
5.1	Introduction et propriétés	17

Première partie

Rappels

1

Matrices classiques

1.1 Matrice orthogonale

Définition 1.1. Une matrice $U \in \mathbb{R}^{n \times n}$ est dite orthogonale si elle vérifie la propriété suivante

$$U^\top U = UU^\top = \text{Id}_n . \quad (1.1)$$

Une telle matrice U peut s'écrire en colonne $U = [u_1, \dots, u_n]$ et ses colonnes satisfont les relations

$$\forall i \in \llbracket 1, n \rrbracket, u_i^\top u_j = \delta_{ij} , \quad (1.2)$$

où le symbole de Kronecker δ est défini pour tout $(i, j) \in \llbracket 1, n \rrbracket$ par

$$\delta_{ij} = \begin{cases} 1, & \text{si } i = j, \\ 0, & \text{si } i \neq j. \end{cases} \quad (1.3)$$

Ainsi les vecteurs u_1, \dots, u_n forment une base orthonormale.

1.2 Matrice J_n et recentrage

Soit $\mathbf{1}_n \in \mathbb{R}^n$ le vecteur de taille n ne contenant que des 1. On définit alors la matrice J_n par

$$J_n = \mathbf{1}_n \mathbf{1}_n^\top \in \mathbb{R}^n \quad (1.4)$$

Propriétés : La matrice J_n est symétrique définie positive :

$$J_n^2 = nJ_n \quad (1.5)$$

On associe souvent aussi le projecteur : \bar{J}_n défini par $\bar{J}_n = \frac{1}{n}J_n$. Le projecteur orthogonal associé $\bar{C}_n = \text{Id}_n - \bar{J}_n$ est la matrice que l'on appelle la *matrice de centrage* car pour tout vecteur $x \in \mathbb{R}^n$ on observe que

$$\bar{C}_n x = (x_1 - \bar{x}_n, \dots, x_n - \bar{x}_n) . \quad (1.6)$$

Décomposition spectrale :

$$J_n = H_n^\top \text{diag}(n, 0, \dots, 0) H_n \quad (1.7)$$

$$\bar{J}_n = H_n^\top \text{diag}(1, 0, \dots, 0) H_n . \quad (1.8)$$

où $H_n \in \mathbb{R}^{n \times n}$ est la matrice de Helmert est la matrice orthogonale définie par :

$$H_n = \begin{bmatrix} \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \dots & \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} \\ \frac{1}{\sqrt{n}} & \frac{-1}{\sqrt{n}} & 0 & 0 & \dots & 0 & 0 \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{6}} & \frac{-2}{\sqrt{6}} & 0 & \dots & 0 & 0 \\ \frac{1}{\sqrt{12}} & \frac{1}{\sqrt{12}} & \frac{1}{\sqrt{12}} & \frac{-3}{\sqrt{12}} & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \dots & \frac{1}{\sqrt{n(n-1)}} & \frac{-(n-1)}{\sqrt{n(n-1)}} \end{bmatrix}$$

Propriétés : Pour tout $(a, b, a', b') \in \mathbb{R}^4$, on a

$$(a \text{Id}_n + b J_n)(a' \text{Id}_n + b' J_n) = aa' \text{Id}_n + (ab' + a'b + nbb') J_n, \quad (1.9)$$

$$(a \text{Id}_n + b J_n)^{-1} = \frac{1}{a} \left(\text{Id}_n - \frac{b}{a + nb} J_n \right), \quad \text{pour } a \neq 0 \text{ et } a \neq -nb, \quad (1.10)$$

$$a \text{Id}_n + b J_n = H_n^\top \text{diag}(a + nb, \underbrace{a, \dots, a}_{(n-1) \text{ fois}}) H_n, \quad (\text{décomp. spectrale}) \quad (1.11)$$

$$\det(a \text{Id}_n + b J_n) = a^{n-1} (a + nb) \quad (1.12)$$

Exemple 1.2. Prenons un modèle à effet aléatoire pour une catégorie à K modalités C_1, \dots, C_K et n observations (avec $n = n_1 + \dots + n_K$) :

$$y = \mu \mathbb{1}_n + \sum_{k=1}^K \mathbb{1}_{C_k} a_k + \varepsilon . \quad (1.13)$$

avec $\varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2 \text{Id}_n)$ et $a \sim \mathcal{N}(0, \sigma_a^2 \text{Id}_K)$. Dans ce cas la matrice de covariance de $y \in \mathbb{R}^n$

s'écrit :

$$\text{Var}(y) = \text{Var}(\epsilon) + \text{Var}([\mathbb{1}_{C_1} \cdots \mathbb{1}_{C_K}] a) \quad (1.14)$$

$$= \sigma_\epsilon^2 \text{Id}_n + [\mathbb{1}_{C_1} \cdots \mathbb{1}_{C_K}] \text{Var}(aa^\top) [\mathbb{1}_{C_1} \cdots \mathbb{1}_{C_K}]^\top \quad (1.15)$$

$$= \sigma_\epsilon^2 \text{Id}_n + [\mathbb{1}_{C_1} \cdots \mathbb{1}_{C_K}] \sigma_a^2 \text{Id}_K [\mathbb{1}_{C_1} \cdots \mathbb{1}_{C_K}]^\top \quad (1.16)$$

$$\text{Var}(y) = \sigma_\epsilon^2 \text{Id}_n + \sigma_a^2 \begin{bmatrix} J_{n_1} & 0 & \cdots & \cdots & 0 \\ 0 & J_{n_2} & \ddots & & \vdots \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ \vdots & & \ddots & J_{n_{K-1}} & 0 \\ 0 & \cdots & \cdots & 0 & J_{n_K} \end{bmatrix} \quad (1.17)$$

$$\text{Var}(y) = \begin{bmatrix} \sigma_\epsilon^2 \text{Id}_{n_1} + \sigma_a^2 J_{n_1} & 0 & \cdots & \cdots & 0 \\ 0 & \sigma_\epsilon^2 \text{Id}_{n_2} + \sigma_a^2 J_{n_2} & \ddots & & \vdots \\ \vdots & & \ddots & \ddots & \vdots \\ \vdots & & & \sigma_\epsilon^2 \text{Id}_{n_{K-1}} + \sigma_a^2 J_{n_{K-1}} & 0 \\ 0 & \cdots & \cdots & 0 & \sigma_\epsilon^2 \text{Id}_{n_K} + \sigma_a^2 J_{n_K} \end{bmatrix} \quad (1.18)$$

On peut donc en déduire avec Eq. (1.10)

$$(\text{Var}(y))^{-1} = \begin{bmatrix} \frac{1}{\sigma_\epsilon^2} \left(\text{Id}_{n_1} - \frac{\sigma_a^2}{\sigma_\epsilon^2 + n_1 \sigma_a^2} J_{n_1} \right) & 0 & \cdots & \cdots & 0 \\ 0 & \ddots & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & 0 \\ 0 & \cdots & \cdots & 0 & \frac{1}{\sigma_\epsilon^2} \left(\text{Id}_{n_K} - \frac{\sigma_a^2}{\sigma_\epsilon^2 + n_K \sigma_a^2} J_{n_K} \right) \end{bmatrix} \quad (1.19)$$

1.3 Matrice stochastique, doublement stochastiques

SENETA (*Non-negative matrices and Markov chains*)

BHATIA (*Matrix analysis*)

2

Inversion de matrices

2.1 Inversion des matrices par blocs

Pour toutes matrices $A \in \mathbb{R}^{n_1 \times n_1}$, $B \in \mathbb{R}^{n_1 \times n_2}$, $C \in \mathbb{R}^{n_2 \times n_1}$, $D \in \mathbb{R}^{n_2 \times n_2}$ telle que les matrices $\begin{bmatrix} A & B \\ C & D \end{bmatrix}$, A et D sont inversibles on a la relation suivante :

$$\begin{aligned} \begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} &= \begin{bmatrix} A^{-1} + A^{-1}B(D - CA^{-1}B)^{-1}CA^{-1} & -A^{-1}B(D - CA^{-1}B)^{-1} \\ -(D - CA^{-1}B)^{-1}CA^{-1} & (D - CA^{-1}B)^{-1} \end{bmatrix} \\ &= \begin{bmatrix} (A - BD^{-1}C)^{-1} & -(A - BD^{-1}C)^{-1}BD^{-1} \\ -D^{-1}C(A - BD^{-1}C)^{-1} & D^{-1}C(A - BD^{-1}C)^{-1}BD^{-1} + D^{-1} \end{bmatrix} . \end{aligned}$$

Conséquence : les déterminants suivants sont égaux :

$$\left| \begin{bmatrix} A & B \\ C & D \end{bmatrix} \right| = |A||D - CA^{-1}B| = |D||A - BD^{-1}C| .$$

De plus si $AC = CA$ montrer qu'alors $\left| \begin{bmatrix} A & B \\ C & D \end{bmatrix} \right| = |AD - CB|$.

Identité de Woodbury sous les mêmes hypothèses :

$$(A + BDC)^{-1} = A^{-1} - A^{-1}B(D^{-1} + CA^{-1}B)^{-1}CA^{-1} . \quad (2.1)$$

La formule précédente donne la relation suivante pour des scalaires $x \neq 0$ et $\delta \neq 0$:

$$\frac{1}{x + \delta} = \frac{1}{x} - \left(\frac{1}{x}\right)^2 \cdot \left(\frac{1}{\delta} + \frac{1}{x}\right)^{-1} . \quad (2.2)$$

Enfin relation suivante pour des vecteurs $\mathbf{u} \in \mathbb{R}^{n_1}$ et $\mathbf{v} \in \mathbb{R}^{n_1}$:

$$(A + \mathbf{u}\mathbf{v}^\top)^{-1} = A^{-1} - \frac{A^{-1}\mathbf{u}\mathbf{v}^\top A^{-1}}{1 + \mathbf{v}^\top A^{-1}\mathbf{u}} . \quad (2.3)$$

Rem: On appelle complément de Schur du bloc D de la matrice M , la matrice de dimension $n_1 \times n_2$ suivante : $A - BD^{-1}C$, qu'on note parfois M/D .

Démonstration. Premier point : commençons par appliquer un premier pivot (par bloc) sur notre matrice, en éliminant la matrice “ C ” en bas à gauche :

$$\begin{bmatrix} I_{n_1} & 0 \\ -CA^{-1} & I_{n_2} \end{bmatrix} \begin{bmatrix} A & B \\ C & D \end{bmatrix} = \begin{bmatrix} A & B \\ 0 & D - CA^{-1}B \end{bmatrix} .$$

On élimine de la même manière le bloc en haut à droite :

$$\begin{bmatrix} I_{n_1} & 0 \\ -CA^{-1} & I_{n_2} \end{bmatrix} \begin{bmatrix} A & B \\ C & D \end{bmatrix} \begin{bmatrix} I_{n_1} & -A^{-1}B \\ 0 & I_{n_2} \end{bmatrix} = \begin{bmatrix} A & B \\ 0 & D - CA^{-1}B \end{bmatrix} \begin{bmatrix} I_{n_1} & -A^{-1}B \\ 0 & I_{n_2} \end{bmatrix} = \begin{bmatrix} A & 0 \\ 0 & D - CA^{-1}B \end{bmatrix} .$$

Remarquons alors que l'on peut facilement inverser les matrices triangulaires par blocs :

$$\begin{bmatrix} I_{n_1} & A^{-1}B \\ 0 & I_{n_2} \end{bmatrix} \begin{bmatrix} I_{n_1} & -A^{-1}B \\ 0 & I_{n_2} \end{bmatrix} = I_{n_1+n_2} \\ \begin{bmatrix} I_{n_1} & 0 \\ CA^{-1} & I_{n_2} \end{bmatrix} \begin{bmatrix} I_{n_1} & 0 \\ -CA^{-1} & I_{n_2} \end{bmatrix} = I_{n_1+n_2} .$$

Ainsi en inversant les matrices diagonales, on obtient la factorisation LDU (Low triangular, Diagonal, Upper triangular)

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} = \begin{bmatrix} I_{n_1} & 0 \\ CA^{-1} & I_{n_2} \end{bmatrix} \begin{bmatrix} A & 0 \\ 0 & D - CA^{-1}B \end{bmatrix} \begin{bmatrix} I_{n_1} & A^{-1}B \\ 0 & I_{n_2} \end{bmatrix} . \quad (2.4)$$

En inversant les deux côtés :

$$\begin{aligned} \begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} &= \begin{bmatrix} I_{n_1} & A^{-1}B \\ 0 & I_{n_2} \end{bmatrix}^{-1} \begin{bmatrix} A & 0 \\ 0 & D - CA^{-1}B \end{bmatrix}^{-1} \begin{bmatrix} I_{n_1} & 0 \\ CA^{-1} & I_{n_2} \end{bmatrix}^{-1} \\ &= \begin{bmatrix} I_{n_1} & -A^{-1}B \\ 0 & I_{n_2} \end{bmatrix} \begin{bmatrix} A^{-1} & 0 \\ 0 & (D - CA^{-1}B)^{-1} \end{bmatrix} \begin{bmatrix} I_{n_1} & 0 \\ -CA^{-1} & I_{n_2} \end{bmatrix} \\ &= \begin{bmatrix} A^{-1} & -A^{-1}B(D - CA^{-1}B)^{-1} \\ 0 & (D - CA^{-1}B)^{-1} \end{bmatrix} \begin{bmatrix} I_{n_1} & 0 \\ -CA^{-1} & I_{n_2} \end{bmatrix} \\ &= \begin{bmatrix} A^{-1} + A^{-1}B(D - CA^{-1}B)^{-1}CA^{-1} & -A^{-1}B(D - CA^{-1}B)^{-1} \\ -(D - CA^{-1}B)^{-1}CA^{-1} & (D - CA^{-1}B)^{-1} \end{bmatrix} . \end{aligned} \quad (2.5)$$

On procède de même pour la seconde relation et on obtient la factorisation UDL (Upper triangular, Diagonal, Lower Triangular) :

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} = \begin{bmatrix} I_{n_1} & BD^{-1} \\ 0 & I_{n_2} \end{bmatrix} \begin{bmatrix} A - BD^{-1}C & 0 \\ 0 & D \end{bmatrix} \begin{bmatrix} I_{n_1} & 0 \\ D^{-1}C & I_{n_2} \end{bmatrix} . \quad (2.6)$$

De nouveau on peut inverser les deux membres :

$$\begin{aligned} \begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} &= \begin{bmatrix} I_{n_1} & 0 \\ D^{-1}C & I_{n_2} \end{bmatrix}^{-1} \begin{bmatrix} A - BD^{-1}C & 0 \\ 0 & D \end{bmatrix}^{-1} \begin{bmatrix} I_{n_1} & BD^{-1} \\ 0 & I_{n_2} \end{bmatrix}^{-1} \\ &= \begin{bmatrix} I_{n_1} & 0 \\ -D^{-1}C & I_{n_2} \end{bmatrix} \begin{bmatrix} (A - BD^{-1}C)^{-1} & 0 \\ 0 & D^{-1} \end{bmatrix} \begin{bmatrix} I_{n_1} & -BD^{-1} \\ 0 & I_{n_2} \end{bmatrix} \\ &= \begin{bmatrix} (A - BD^{-1}C)^{-1} & -(A - BD^{-1}C)^{-1}BD^{-1} \\ -D^{-1}C(A - BD^{-1}C)^{-1} & D^{-1}C(A - BD^{-1}C)^{-1}BD^{-1} + D^{-1} \end{bmatrix} . \end{aligned} \quad (2.7)$$

Second point : il suffit de calculer les déterminants dans les relations données par les Équations (2.4) et (2.6). \square

3

Décompositions classiques

3.1 Décomposition spectrale

HORN et JOHNSON (*Topics in matrix analysis*)

GOLUB et VAN LOAN (*Matrix computations*)

STRANG (*Introduction to linear algebra*)

3.1.1 Valeurs propres du laplacien sur graphe

<http://www.math.ucsd.edu/~fan/research/cb/ch1.pdf>

3.2 Décomposition en valeur singulière (SVD)

Deuxième partie

Outils pour l'ANOVA

4

Matrice pour l'analyse de la variance

Plan d'expériences : on observe K classes C_1, \dots, C_K (e.g., les variétés de blé sur une parcelle) et n observations d'un phénomène (e.g., le rendement de la variétés) sont considérées. On fait l'hypothèse que les classes C_k sont disjointes et forment une partition des observations : $\cup_{k=1}^K C_k = \llbracket 1, n \rrbracket$ et $\forall (k, k') \in \llbracket 1, K \rrbracket, C_k \cap C_{k'} = \emptyset$. On appelle cet encodage l'encodage “un-chaud” (🇬🇧 : *one-hot*) ou par variable indicatrice, ou encore par variable factice (🇬🇧 : *dummy variable*). Enfin on suppose que la cardinalité de chaque classe C_k est n_k , et donc que $n = \sum_{k=1}^K n_k$.

Le modèle de l'ANOVA peut alors s'écrire, sous l'hypothèse gaussienne que pour tout $i \in \llbracket 1, n \rrbracket, \varepsilon_i \stackrel{i.i.d.}{\sim} \mathcal{N}(0, \sigma^2)$ et pour tout $(i, k) \in \llbracket 1, n \rrbracket \times \llbracket 1, K \rrbracket$,

$$y_i = \mu + a_k \delta_{i, C_k} + \varepsilon_i \quad (4.1)$$

$$\text{où } \delta_{i, C_k} = \begin{cases} 1, & \text{si } i \in C_k \\ 0, & \text{si } i \notin C_k \end{cases}.$$

Interprétation : les a_k sont les coefficients qui correspondent au niveau d'influence de la k^{e} classe

$$y = \underbrace{\begin{bmatrix} \mathbb{1}_n & \mathbb{1}_{C_1} & \dots & \mathbb{1}_{C_K} \end{bmatrix}}_X \underbrace{\begin{bmatrix} \mu \\ a_1 \\ \vdots \\ a_K \end{bmatrix}}_{\beta} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_K \end{bmatrix}. \quad (4.2)$$

Remarque 4.1. La matrice $X \in \mathbb{R}^{n \times K+1}$ est de rang K car $\mathbb{1}_n = \sum_{k=1}^K \mathbb{1}_{C_k}$ et les vecteurs $\mathbb{1}_{C_1}, \dots, \mathbb{1}_{C_K}$ sont linéairement indépendants et générateurs (cela est vrai car les classes C_k sont disjointes et forment une partition de l'espace : $\cup_{k=1}^K C_k = \llbracket 1, n \rrbracket$). Ainsi on ne peut pas appliquer la formule $(X^\top X)^{-1} X^\top y$ pour obtenir une solution des moindres carrés : en effet $\text{rg}(X) = \text{rg}(X^\top X) = K < K + 1$ mais $X^\top X \in \mathbb{R}^{(K+1) \times (K+1)}$.

On peut expliciter la matrice de Gram $X^\top X$ dans ce contexte :

$$X^\top X = \begin{bmatrix} n & n_1 & \cdots & \cdots & n_K \\ n_1 & n_1 & 0 & \cdots & 0 \\ \vdots & 0 & \ddots & \ddots & \vdots \\ \vdots & \vdots & \ddots & n_{K-1} & 0 \\ n_K & 0 & \cdots & 0 & n_K \end{bmatrix} .$$

4.1 Moindres carrées et contraintes

On cherche pour l'estimation des moindres carrés à résoudre le problème suivants, avec des contraintes sur les a_k , ce qui correspond à

$$\min_{\beta \in \mathbb{R}^{K+1}} \frac{1}{2} \|y - X\beta\|^2 , \quad (4.3)$$

$$\text{t.q. } \beta = (\mu, a_1, \dots, a_K)^\top \text{ et } \sum_{k=1}^K c_k a_k = 0 , \quad (4.4)$$

où le vecteur $c = (c_1, \dots, c_K)^\top \in \mathbb{R}^K$ est un vecteur encodant les contraintes choisies tel que $\sum_{k=1}^K c_k \neq 0$. On distingue trois types de contraintes :

1. Le cas où l'on choisit une classe C_{k_0} comme référence. Cela revient à prendre $c = (0, \dots, \underbrace{1}_{\text{en } k_0^{\text{e}} \text{ position}}, \dots, 0)$, ce qui revient à la contrainte " $a_{k_0} = 0$ ".
2. Le cas où l'on choisit des contributions des classes centrées autour de la moyenne $c = (1, \dots, 1)$, ce qui revient à la contrainte $\sum_{k=1}^K a_k = 0$.
3. Le cas où l'on choisit des contributions pondérées des classes centrées autour de la moyenne pondérée $c = (n_1, \dots, n_K)$, ce qui revient à la contrainte $\sum_{k=1}^K n_k a_k = 0$.

Formation du Lagrangien :

$$\mathcal{L}(\beta, \gamma) = \frac{1}{2} \|y - X\beta\|^2 + \gamma a^\top c . \quad (4.5)$$

Condition nécessaire du premier ordre :

$$\frac{\partial \mathcal{L}(\beta, \gamma)}{\partial \beta} = 0 \iff X^\top (X\beta - y) + \gamma c = 0 \quad (4.6)$$

$$\iff X^\top X\beta + \gamma c = X^\top y \quad (4.7)$$

$$\iff \begin{bmatrix} n & n_1 & \cdots & \cdots & n_K & 0 \\ n_1 & n_1 & 0 & \cdots & 0 & c_1 \\ \vdots & 0 & \ddots & \ddots & \vdots & \vdots \\ \vdots & \vdots & \ddots & n_{K-1} & 0 & c_{K-1} \\ n_K & 0 & \cdots & 0 & n_K & c_K \\ 0 & c_1 & \cdots & c_{K-1} & c_K & 0 \end{bmatrix} \begin{bmatrix} \beta \\ \gamma \end{bmatrix} = \begin{bmatrix} X^\top y \\ 0 \end{bmatrix} . \quad (4.8)$$

Tout d'abord il est facile de vérifier que $X^\top y = \begin{bmatrix} n\bar{y}_n \\ n_1\bar{y}_{C_1} \\ \vdots \\ n_K\bar{y}_{C_K} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i \in C_1} y_i \\ \vdots \\ \sum_{i \in C_K} y_i \end{bmatrix}$ avec la notation

$\bar{y}_{C_k} = \frac{1}{n_k} \sum_{i \in C_k} y_i$ pour tout $k \in \llbracket 1, K \rrbracket$.

En multipliant par à gauche par la matrice $\text{diag}(\frac{1}{n}, \frac{1}{n_1}, \dots, \frac{1}{n_K}, 1)$ le système précédent on obtient :

$$\begin{bmatrix} 1 & \frac{n_1}{n} & \cdots & \cdots & \frac{n_K}{n} & 0 \\ 1 & 1 & 0 & \cdots & 0 & \frac{c_1}{n_1} \\ \vdots & 0 & \ddots & \ddots & \vdots & \vdots \\ \vdots & \vdots & \ddots & 1 & 0 & \frac{c_{K-1}}{n_{K-1}} \\ 1 & 0 & \cdots & 0 & 1 & \frac{c_K}{n_K} \\ 0 & c_1 & \cdots & c_{K-1} & c_K & 0 \end{bmatrix} \begin{bmatrix} \mu \\ a \\ \gamma \end{bmatrix} = \begin{bmatrix} \bar{y}_n \\ \bar{y}_{C_1} \\ \vdots \\ \bar{y}_{C_K} \\ 0 \end{bmatrix}. \quad (4.9)$$

On en déduit en prenant les équation de la ligne 2 à $K + 1$ les équations :

$$\begin{cases} \hat{a}_K = \bar{y}_{C_K} - \hat{\mu} - \frac{c_K}{n_K} \gamma \\ \vdots \\ \hat{a}_k = \bar{y}_{C_k} - \hat{\mu} - \frac{c_k}{n_k} \gamma \\ \vdots \\ \hat{a}_1 = \bar{y}_{C_1} - \hat{\mu} - \frac{c_1}{n_1} \gamma \end{cases} \quad (4.10)$$

Avec la première équation du système précédent, i.e.,

$$\hat{\mu} + \sum_{k=1}^K \frac{n_k}{n} a_k = \bar{y}_n \quad (4.11)$$

et en sommant avec les poids du système d'équation précédent, on obtient :

$$\sum_{k=1}^K \frac{n_k}{n} \hat{a}_k = \sum_{k=1}^K \frac{n_k}{n} \bar{y}_{C_k} - \hat{\mu} + \frac{\gamma}{n} \sum_{k=1}^K c_k \quad (4.12)$$

ce qui implique que

$$\frac{\gamma}{n} \sum_{k=1}^K c_k = 0. \quad (4.13)$$

Rappelant la condition $\sum_{k=1}^K c_k \neq 0$, on en déduit que $\gamma = 0$.

Enfin, en sommant avec les poids $c_K, \dots, c_k, \dots, c_1$ les système d'équations dans (4.10), on obtient :

$$\begin{aligned} 0 &= \sum_{k=1}^K c_k \hat{a}_k = \sum_{k=1}^K c_k \bar{y}_{C_k} - \sum_{k=1}^K c_k \hat{\mu} - \sum_{k=1}^K \frac{c_k^2}{n_K} \gamma = \sum_{k=1}^K c_k \bar{y}_{C_k} - \sum_{k=1}^K c_k \hat{\mu} \\ \iff \hat{\mu} &= \frac{\sum_{k=1}^K c_k \bar{y}_{C_k}}{\sum_{k=1}^K c_k} \end{aligned}$$

On obtient donc comme solution du système initiale

$$\left\{ \begin{array}{lcl} \hat{\mu} & = & \frac{\sum_{k=1}^K c_k \bar{y}_{C_K}}{\sum_{k=1}^K c_k} \\ \hat{a}_1 & = & \bar{y}_{C_1} - \hat{\mu} \\ \vdots & & \\ \hat{a}_k & = & \bar{y}_{C_k} - \hat{\mu} \\ \vdots & & \\ \hat{a}_K & = & \bar{y}_{C_K} - \hat{\mu} \end{array} \right. \quad (4.14)$$

Retour sur les trois cas possible :

1. $c = (0, \dots, \underbrace{1}_{\text{en } k_0^{\text{e}} \text{ position}}, \dots, 0) :$

$$\left\{ \begin{array}{lcl} \hat{\mu} & = & \bar{y}_{C_{k_0}} \quad (\text{moyenne de la modalité de référence}) \\ \hat{a}_1 & = & \bar{y}_{C_1} - \bar{y}_{C_{k_0}} \\ \vdots & & \\ \hat{a}_k & = & 0 \\ \vdots & & \\ \hat{a}_K & = & \bar{y}_{C_K} - \bar{y}_{C_{k_0}} \end{array} \right. \quad (4.15)$$

2. Le cas où $c = (1, \dots, 1) :$

$$\left\{ \begin{array}{lcl} \hat{\mu} & = & \frac{1}{K} \sum_{k=1}^K \bar{y}_{C_K} \quad (\text{moyenne des moyennes par classes}) \\ \hat{a}_1 & = & \bar{y}_{C_1} - \hat{\mu} \\ \vdots & & \\ \hat{a}_k & = & \bar{y}_{C_k} - \hat{\mu} \\ \vdots & & \\ \hat{a}_K & = & \bar{y}_{C_K} - \hat{\mu} \end{array} \right. \quad (4.16)$$

3. Le cas où $c = (n_1, \dots, n_K) :$

$$\left\{ \begin{array}{lcl} \hat{\mu} & = & \bar{y}_n \quad (\text{moyenne des observations}) \\ \hat{a}_1 & = & \bar{y}_{C_1} - \hat{\mu} \\ \vdots & & \\ \hat{a}_k & = & \bar{y}_{C_k} - \hat{\mu} \\ \vdots & & \\ \hat{a}_K & = & \bar{y}_{C_K} - \hat{\mu} \end{array} \right. \quad (4.17)$$

Exercice 4.1. : calculer les conditionnement et choisir numériquement la meilleur contrainte

5

Produit de Kronecker

5.1 Introduction et propriétés

Définition 5.1. Soient $A \in \mathbb{R}^{m \times n}$ et $B \in \mathbb{R}^{p \times q}$. Leur produit tensoriel ou produit de Kronecker est la matrice $A \otimes B \in \mathbb{R}^{mp \times nq}$, définie par blocs successifs de taille $p \times q$, le bloc d'indice i, j valant $a_{ij}B$, ou de manière équivalente :

$$A \otimes B = \begin{bmatrix} a_{1,1}B & \cdots & a_{1,n}B \\ \vdots & \ddots & \vdots \\ a_{m,1}B & \cdots & a_{m,n}B \end{bmatrix} \quad (5.1)$$

ou encore

$$A \otimes B = \begin{bmatrix} a_{1,1}b_{1,1} & a_{1,1}b_{1,2} & \cdots & a_{1,1}b_{1,q} & \cdots & \cdots & a_{1,n}b_{1,1} & a_{1,n}b_{1,2} & \cdots & a_{1,n}b_{1,q} \\ a_{1,1}b_{2,1} & a_{1,1}b_{2,2} & \cdots & a_{1,1}b_{2,q} & \cdots & \cdots & a_{1,n}b_{2,1} & a_{1,n}b_{2,2} & \cdots & a_{1,n}b_{2,q} \\ \vdots & \vdots & \ddots & \vdots & & & \vdots & \vdots & \ddots & \vdots \\ a_{1,1}b_{p,1} & a_{1,1}b_{p,2} & \cdots & a_{1,1}b_{p,q} & \cdots & \cdots & a_{1,n}b_{p,1} & a_{1,n}b_{p,2} & \cdots & a_{1,n}b_{p,q} \\ \vdots & \vdots & & \vdots & \ddots & & \vdots & \vdots & & \vdots \\ \vdots & \vdots & & \vdots & & \ddots & \vdots & \vdots & & \vdots \\ a_{m,1}b_{1,1} & a_{m,1}b_{1,2} & \cdots & a_{m,1}b_{1,q} & \cdots & \cdots & a_{m,n}b_{1,1} & a_{m,n}b_{1,2} & \cdots & a_{m,n}b_{1,q} \\ a_{m,1}b_{2,1} & a_{m,1}b_{2,2} & \cdots & a_{m,1}b_{2,q} & \cdots & \cdots & a_{m,n}b_{2,1} & a_{m,n}b_{2,2} & \cdots & a_{m,n}b_{2,q} \\ \vdots & \vdots & \ddots & \vdots & & & \vdots & \vdots & \ddots & \vdots \\ a_{m,1}b_{p,1} & a_{m,1}b_{p,2} & \cdots & a_{m,1}b_{p,q} & \cdots & \cdots & a_{m,n}b_{p,1} & a_{m,n}b_{p,2} & \cdots & a_{m,n}b_{p,q} \end{bmatrix} \quad (5.2)$$

Propriétés et liens avec les opérations usuelles : Prenons A, B, C et D quatre matrices quelconques. Alors les relations suivantes sont satisfaites :

$$A \otimes (B + C) = A \otimes B + A \otimes C, \quad (5.3)$$

$$(B + C) \otimes A = B \otimes A + C \otimes A, \quad (5.4)$$

$$(\lambda A) \otimes B = A \otimes (\lambda B) = \lambda(A \otimes B) \quad (\text{pour } \lambda \in \mathbb{R}), \quad (5.5)$$

$$(A \otimes B) \otimes C = A \otimes (B \otimes C), \quad (5.6)$$

$$A \otimes 0 = 0 \otimes A = 0, \quad (5.7)$$

$$(A \otimes B)(C \otimes D) = (AC) \otimes (BD) \quad (\text{quand } AC \text{ et } BD \text{ existent}), \quad (5.8)$$

$$(A \otimes B)^\top = (A^\top \otimes B^\top), \quad (5.9)$$

$$\begin{bmatrix} A_1 & A_2 \end{bmatrix} \otimes B = \begin{bmatrix} A_1 \otimes B & A_2 \otimes B \end{bmatrix} \quad (\text{pour des matrices matrice concaténées}), \quad (5.10)$$

$$(A \otimes B)^{-1} = A^{-1} \otimes B^{-1} \quad (\text{pour } A \text{ et } B \text{ inversibles}). \quad (5.11)$$

Propriétés spectrales Prenons des éléments spectraux des matrices $A \in \mathbb{R}^{n \times n}$ et $B \in \mathbb{R}^{m \times m}$, i.e., $Ax = ax$ et $By = \beta y$, alors

$$(A \otimes B)(x \otimes y) = a\beta(x \otimes y) . \quad (5.12)$$

et par conséquent si l'on prend $\{a_1, \dots, a_n\}, \{x_1, \dots, x_n\}$ et $\{\beta_1, \dots, \beta_m\}, \{y_1, \dots, y_m\}$ les couples valeurs/vecteurs propres des matrices A et B , alors la matrice $A \otimes B$ a pour éléments propres $\{a_i\beta_j, i = 1, \dots, n, j = 1, \dots, m\}$ et $\{x_i y_j, i = 1, \dots, n, j = 1, \dots, m\}$. Ainsi

$$\text{tr}(A \otimes B) = \text{tr}(A) \text{tr}(B), \quad (5.13)$$

$$\det(A \otimes B) = \det(A)^m \det(B)^n, \quad (5.14)$$

$$\text{rg}(A \otimes B) = \text{rg}(A) \text{rg}(B). \quad (5.15)$$

References

CLARKE (*Linear models : the theory and application of analysis of variance*)

SEARLE, CASELLA et McCULLOCH (*Variance components*)

Bibliographie

- BHATIA, R. *Matrix analysis*. T. 169. Graduate Texts in Mathematics. New York : Springer-Verlag, 1997 (p. 7).
- CLARKE, B. R. *Linear models : the theory and application of analysis of variance*. T. 634. John Wiley & Sons, 2008 (p. 18).
- GOLUB, G. H. et C. F. VAN LOAN. *Matrix computations*. Fourth. Johns Hopkins University Press, Baltimore, MD, 2013, p. xiv+756 (p. 11).
- HORN, R. A. et C. R. JOHNSON. *Topics in matrix analysis*. Corrected reprint of the 1991 original. Cambridge : Cambridge University Press, 1994, p. viii+607 (p. 11).
- SEARLE, S. R., G. CASELLA et C. E. MCCULLOCH. *Variance components*. T. 391. John Wiley & Sons, 2009 (p. 18).
- SENETA, E. *Non-negative matrices and Markov chains*. Springer Series in Statistics. New York : Springer, 2006, p. xvi+287 (p. 7).
- STRANG, G. *Introduction to linear algebra*. 5th edition. Wellesley, MA : Wellesley-Cambridge Press, 2016, p. x + 574 (p. 11).