

Analyse 1: Algorithme pour l'optimisation sans contrainte

Joseph Salmon

Septembre 2014

La descente de gradient : intuition

- ▶ Enjeu : minimiser f (dans \mathbb{R}^d) en trouvant un nouveau point pour lequel f diminue le plus.
- ▶ Approximation du premier ordre :

$$f(x) \approx f(x^0) + \langle \nabla f(x^0), x - x^0 \rangle$$

- ▶ Solution : il faut “s’aligner” avec la direction opposée au gradient $x - x_0 = -\alpha \nabla f(x^0)$
 $\alpha > 0$ contrôle la “vitesse” avec laquelle on progresse dans la direction. Ce paramètre est appelé le **pas** de la méthode.

La descente de gradient : algorithme

Data: initialisation x^0 , nb max. d'itérations T , critère d'arrêt ε , pas α

Result: un point x_T "proche" du minimum de la fonction f


for $1 \leq t \leq T$ **do**

$x^{t+1} \leftarrow x^t - \alpha \nabla f(x^t)$

 STOP si critère d'arrêt inférieur à ε
end

Critères d'arrêts possibles :

- ▶ $\|\nabla f(x^t)\| \leq \varepsilon$
- ▶ $f(x^{t+1}) - f(x^t) \leq \varepsilon$
- ▶ $\|x^{t+1} - x^t\| \leq \varepsilon$ ou $\frac{\|x^{t+1} - x^t\|}{\|x^t\|} \leq \varepsilon$



La descente de gradient : algorithme

Data: initialisation x^0 , nb max. d'itérations T , critère d'arrêt ε , pas α

Result: un point x_T "proche" du minimum de la fonction f


for $1 \leq t \leq T$ **do**

$$x^{t+1} \leftarrow x^t - \alpha \nabla f(x^t)$$

STOP si critère d'arrêt inférieur à ε
end

Critères d'arrêts possibles :

- ▶ $\|\nabla f(x^t)\| \leq \varepsilon$
- ▶ $f(x^{t+1}) - f(x^t) \leq \varepsilon$
- ▶ $\|x^{t+1} - x^t\| \leq \varepsilon$ ou $\frac{\|x^{t+1} - x^t\|}{\|x^t\|} \leq \varepsilon$



La descente de gradient : algorithme

Data: initialisation x^0 , nb max. d'itérations T , critère d'arrêt ε , pas α

Result: un point x_T "proche" du minimum de la fonction f


for $1 \leq t \leq T$ **do**

$x^{t+1} \leftarrow x^t - \alpha \nabla f(x^t)$

 STOP si critère d'arrêt inférieur à ε
end

Critères d'arrêts possibles :

- ▶ $\|\nabla f(x^t)\| \leq \varepsilon$
- ▶ $f(x^{t+1}) - f(x^t) \leq \varepsilon$
- ▶ $\|x^{t+1} - x^t\| \leq \varepsilon$ ou $\frac{\|x^{t+1} - x^t\|}{\|x^t\|} \leq \varepsilon$



La descente de gradient : algorithme

Data: initialisation x^0 , nb max. d'itérations T , critère d'arrêt ε , pas α

Result: un point x_T "proche" du minimum de la fonction f


for $1 \leq t \leq T$ **do**

$x^{t+1} \leftarrow x^t - \alpha \nabla f(x^t)$

 STOP si critère d'arrêt inférieur à ε
end

Critères d'arrêts possibles :

- ▶ $\|\nabla f(x^t)\| \leq \varepsilon$
- ▶ $f(x^{t+1}) - f(x^t) \leq \varepsilon$
- ▶ $\|x^{t+1} - x^t\| \leq \varepsilon$ ou $\frac{\|x^{t+1} - x^t\|}{\|x^t\|} \leq \varepsilon$



La descente de gradient : algorithme

Data: initialisation x^0 , nb max. d'itérations T , critère d'arrêt ε , pas α

Result: un point x_T "proche" du minimum de la fonction f


for $1 \leq t \leq T$ **do**

$x^{t+1} \leftarrow x^t - \alpha \nabla f(x^t)$

 STOP si critère d'arrêt inférieur à ε
end

Critères d'arrêts possibles :

- ▶ $\|\nabla f(x^t)\| \leq \varepsilon$
- ▶ $f(x^{t+1}) - f(x^t) \leq \varepsilon$
- ▶ $\|x^{t+1} - x^t\| \leq \varepsilon$ ou $\frac{\|x^{t+1} - x^t\|}{\|x^t\|} \leq \varepsilon$



La descente de gradient : algorithme

Data: initialisation x^0 , nb max. d'itérations T , critère d'arrêt ε , pas α

Result: un point x_T "proche" du minimum de la fonction f


for $1 \leq t \leq T$ **do**

$x^{t+1} \leftarrow x^t - \alpha \nabla f(x^t)$

 STOP si critère d'arrêt inférieur à ε
end

Critères d'arrêts possibles :


- ▶ $\|\nabla f(x^t)\| \leq \varepsilon$
- ▶ $f(x^{t+1}) - f(x^t) \leq \varepsilon$
- ▶ $\|x^{t+1} - x^t\| \leq \varepsilon$ ou $\frac{\|x^{t+1} - x^t\|}{\|x^t\|} \leq \varepsilon$



Attention au choix du pas (cas 1D)

$$x^{t+1} = x^t - \alpha \nabla f(x^t)$$

α : paramètre crucial pour obtenir la convergence vers un minimum




Divergence : pas beaucoup trop grand

Attention au choix du pas (cas 1D)

$$x^{t+1} = x^t - \alpha \nabla f(x^t)$$

α : paramètre crucial pour obtenir la convergence vers un minimum




Convergence lente : pas trop grand

Attention au choix du pas (cas 1D)

$$x^{t+1} = x^t - \alpha \nabla f(x^t)$$

α : paramètre crucial pour obtenir la convergence vers un minimum




Convergence rapide : bon pas

Attention au choix du pas (cas 1D)

$$x^{t+1} = x^t - \alpha \nabla f(x^t)$$

α : paramètre crucial pour obtenir la convergence vers un minimum




Convergence lente : pas trop petit


Attention au choix du pas (cas 2D)

$$x^{t+1} = x^t - \alpha \nabla f(x^t)$$

α : paramètre crucial pour obtenir la convergence vers un minimum



Trop pas grand



Trop petit pas

Recherche linéaire I

Parfois, il faut choisir le pas à chaque itération : α^t évolue avec les itérations. On note $d^t = -\nabla f(x^t)$ une direction de descente

Règle de la minimisation

Minimisation sur l'amplitude : il faut résoudre le problème 1D :


$$f(x^t + \alpha^t d^t) = \min_{\alpha \geq 0} f(x^t + \alpha d^t)$$

Rem: Pour cela il faut que le problème 1D soit simple à résoudre

Recherche linéaire II

Règle d'Armijo (ou du *backtracking* géométrique)


En fixant $s > 0$, $\sigma \in]0, 1[$, et $\beta \in]0, 1[$, il s'agit de choisir $\alpha^t = \beta^{m_t} s$: où m_t est le premier entier non nul tel que $f(x^t + \beta^m s d^t) - f(x^t) \leq \sigma \beta^m s \langle \nabla f(x^t), d^t \rangle = -\sigma \beta^m s \|\nabla f(x^t)\|^2$



Recherche linéaire II

Règle d'Armijo (ou du *backtracking* géométrique)


En fixant $s > 0$, $\sigma \in]0, 1[$, et $\beta \in]0, 1[$, il s'agit de choisir $\alpha^t = \beta^{m_t} s$: où m_t est le premier entier non nul tel que $f(x^t + \beta^m s d^t) - f(x^t) \leq \sigma \beta^m s \langle \nabla f(x^t), d^t \rangle = -\sigma \beta^m s \|\nabla f(x^t)\|^2$



Recherche linéaire II

Règle d'Armijo (ou du *backtracking* géométrique)


En fixant $s > 0$, $\sigma \in]0, 1[$, et $\beta \in]0, 1[$, il s'agit de choisir $\alpha^t = \beta^{m_t} s$: où m_t est le premier entier non nul tel que $f(x^t + \beta^m s d^t) - f(x^t) \leq \sigma \beta^m s \langle \nabla f(x^t), d^t \rangle = -\sigma \beta^m s \|\nabla f(x^t)\|^2$



Recherche linéaire II

Règle d'Armijo (ou du *backtracking* géométrique)


En fixant $s > 0$, $\sigma \in]0, 1[$, et $\beta \in]0, 1[$, il s'agit de choisir $\alpha^t = \beta^{m_t} s$: où m_t est le premier entier non nul tel que $f(x^t + \beta^m s d^t) - f(x^t) \leq \sigma \beta^m s \langle \nabla f(x^t), d^t \rangle = -\sigma \beta^m s \|\nabla f(x^t)\|^2$



Recherche linéaire II

Règle d'Armijo (ou du *backtracking* géométrique)


En fixant $s > 0$, $\sigma \in]0, 1[$, et $\beta \in]0, 1[$, il s'agit de choisir $\alpha^t = \beta^{m_t} s$: où m_t est le premier entier non nul tel que $f(x^t + \beta^m s d^t) - f(x^t) \leq \sigma \beta^m s \langle \nabla f(x^t), d^t \rangle = -\sigma \beta^m s \|\nabla f(x^t)\|^2$



Recherche linéaire II

Règle d'Armijo (ou du *backtracking* géométrique)


En fixant $s > 0$, $\sigma \in]0, 1[$, et $\beta \in]0, 1[$, il s'agit de choisir $\alpha^t = \beta^{m_t} s$: où m_t est le premier entier non nul tel que

$$f(x^t + \beta^m s d^t) - f(x^t) \leq \sigma \beta^m s \langle \nabla f(x^t), d^t \rangle = -\sigma \beta^m s \|\nabla f(x^t)\|^2$$


Recherche linéaire II

Règle d'Armijo (ou du *backtracking* géométrique)

En fixant $s > 0$, $\sigma \in]0, 1[$, et $\beta \in]0, 1[$, il s'agit de choisir $\alpha^t = \beta^{m_t} s$: où m_t est le premier entier non nul tel que

$$f(x^t + \beta^m s d^t) - f(x^t) \leq \sigma \beta^m s \langle \nabla f(x^t), d^t \rangle = -\sigma \beta^m s \|\nabla f(x^t)\|^2$$


Recherche linéaire III

Règle d'Armijo (ou du *backtracking*)

En pratique on fait souvent les choix, cf. Bertsekas (1999) :

- ▶ $s = 1$
- ▶ $\beta = 1/2$ ou $\beta = 1/10$
- ▶ $\sigma \in [10^{-5}, 10^{-1}]$

Détour par la méthode de Newton

Objectif : la méthode de Newton (ou Newton-Raphson) sert à trouver les zéros d'une fonction, *i.e.*, résoudre $f(x) = 0$

L'idée : approximation locale par une fonction affine

$$f(x) \approx f(x^0) + f'(x^0)(x - x^0)$$

La règle de mise à jour est donc :

$$x^{t+1} \leftarrow x^t - \frac{f'(x^t)}{f(x^t)}$$

Détour par la méthode de Newton II

Data: point initial x^0 , nombre max. d'itérations T , critère d'arrêt ε


Result: un point x_T "proche" du minimum de la fonction f

for $1 \leq t \leq T - 1$ **do**

$$x^{t+1} \leftarrow x^t - \frac{f'(x^t)}{f''(x^t)}$$

STOP si critère d'arrêt inférieur à ε

end



Détour par la méthode de Newton II

Data: point initial x^0 , nombre max. d'itérations T , critère d'arrêt ε


Result: un point x_T "proche" du minimum de la fonction f

for $1 \leq t \leq T - 1$ **do**

$$x^{t+1} \leftarrow x^t - \frac{f'(x^t)}{f''(x^t)}$$

STOP si critère d'arrêt inférieur à ε

end



Détour par la méthode de Newton II

Data: point initial x^0 , nombre max. d'itérations T , critère d'arrêt ε


Result: un point x_T "proche" du minimum de la fonction f

for $1 \leq t \leq T - 1$ **do**

$$x^{t+1} \leftarrow x^t - \frac{f'(x^t)}{f''(x^t)}$$

STOP si critère d'arrêt inférieur à ε

end



Détour par la méthode de Newton II

Data: point initial x^0 , nombre max. d'itérations T , critère d'arrêt ε


Result: un point x_T "proche" du minimum de la fonction f

for $1 \leq t \leq T - 1$ **do**

$$x^{t+1} \leftarrow x^t - \frac{f'(x^t)}{f''(x^t)}$$

STOP si critère d'arrêt inférieur à ε

end



Détour par la méthode de Newton II

Data: point initial x^0 , nombre max. d'itérations T , critère d'arrêt ε


Result: un point x_T "proche" du minimum de la fonction f

for $1 \leq t \leq T - 1$ **do**

$$x^{t+1} \leftarrow x^t - \frac{f'(x^t)}{f''(x^t)}$$

STOP si critère d'arrêt inférieur à ε

end



Méthode de Newton pour la minimisation

Localement, en un point x^0 une fonction deux fois différentiable ressemble à :

$$f(x) \approx f(x^*) + \langle \nabla f(x^*), x - x^* \rangle + \frac{1}{2}(x - x^*)^\top \nabla^2 f(x^*)(x - x^*)$$

- ▶ Enjeu : minimiser en x l'approximation (quadratique) précédente
- ▶ Solution : CNO

$$\nabla f(x^*) + \nabla^2 f(x^*)(x - x^*) = 0$$

- ▶ Nouvelle règle de mise à jour :

$$x^{t+1} \leftarrow x^t - (\nabla^2 f(x^t))^{-1} \nabla f(x^t)$$

Rem: C'est donc la méthode de Newton appliquée à la recherche de zéros d'une approximation du gradient de f

Méthode de Newton pour la minimisation : algorithme

Data: point initial x^0 , nombre max. d'itérations T , critère d'arrêt ε


Result: un point x_T "proche" du minimum de la fonction f

for $1 \leq t \leq T - 1$ **do**

$x^{t+1} \leftarrow x^t - (\nabla^2 f(x^t))^{-1} \nabla f(x^t)$

 STOP si critère d'arrêt inférieur à ε

end



Méthode de Newton pour la minimisation : algorithme

Data: point initial x^0 , nombre max. d'itérations T , critère d'arrêt ε


Result: un point x_T "proche" du minimum de la fonction f

for $1 \leq t \leq T - 1$ **do**

$x^{t+1} \leftarrow x^t - (\nabla^2 f(x^t))^{-1} \nabla f(x^t)$

 STOP si critère d'arrêt inférieur à ε

end



Méthode de Newton pour la minimisation : algorithme

Data: point initial x^0 , nombre max. d'itérations T , critère d'arrêt ε


Result: un point x_T "proche" du minimum de la fonction f

for $1 \leq t \leq T - 1$ **do**

$x^{t+1} \leftarrow x^t - (\nabla^2 f(x^t))^{-1} \nabla f(x^t)$

 STOP si critère d'arrêt inférieur à ε

end



Méthode de Newton pour la minimisation : algorithme

Data: point initial x^0 , nombre max. d'itérations T , critère d'arrêt ε


Result: un point x_T "proche" du minimum de la fonction f

for $1 \leq t \leq T - 1$ **do**

$x^{t+1} \leftarrow x^t - (\nabla^2 f(x^t))^{-1} \nabla f(x^t)$

 STOP si critère d'arrêt inférieur à ε

end



Méthode de Newton pour la minimisation : algorithme

Data: point initial x^0 , nombre max. d'itérations T , critère d'arrêt ε


Result: un point x_T "proche" du minimum de la fonction f

for $1 \leq t \leq T - 1$ **do**

$x^{t+1} \leftarrow x^t - (\nabla^2 f(x^t))^{-1} \nabla f(x^t)$

 STOP si critère d'arrêt inférieur à ε

end



Références I

- ▶ D. P. Bertsekas.
Nonlinear programming.
Athena Scientific, 1999.