

NL-Means et Procédures d'Agrégation

Joseph Salmon ¹

¹LPMA-UMR 7599
Université Paris Diderot - Paris 7

10 Décembre 2009 - Séminaire Image du Greyc

NL-Means et agrégation

Cadre

- Estimer une image I à partir d'une observation bruitée Y
 $Y = f + \sigma\varepsilon$ (ε bruit blanc gaussien)

NL-Means et agrégation

Cadre

- Estimer une image I à partir d'une observation bruitée Y
$$Y = f + \sigma\varepsilon \quad (\varepsilon \text{ bruit blanc gaussien})$$

État de l'art

- Solution classique : moyenne locale des valeurs des pixels
- Approche « Patch » : utiliser des voisinages de pixels plutôt que les pixels seuls
- NL-Means : Lissage gaussien dans l'espace des patches

NL-Means et agrégation

Cadre

- ▶ Estimer une image I à partir d'une observation bruitée Y
$$Y = f + \sigma\varepsilon \quad (\varepsilon \text{ bruit blanc gaussien})$$

État de l'art

- ▶ Solution classique : moyenne locale des valeurs des pixels
- ▶ Approche « Patch » : utiliser des voisinages de pixels plutôt que les pixels seuls
- ▶ NL-Means : Lissage gaussien dans l'espace des patches

Le point de vue agrégé

- ▶ Relire les NL-Means comme la recherche d'un noyau local optimal, une combinaison optimale de pixels
- ▶ Cadre de l'agrégation statistique
- ▶ Point de vue différent et des résultats nouveaux

NL-Means et agrégation

Cadre

- ▶ Estimer une image I à partir d'une observation bruitée Y
$$Y = f + \sigma \varepsilon \quad (\varepsilon \text{ bruit blanc gaussien})$$

État de l'art

- ▶ Solution classique : moyenne locale des valeurs des pixels
- ▶ Approche « Patch » : utiliser des voisinages de pixels plutôt que les pixels seuls
- ▶ NL-Means : Lissage gaussien dans l'espace des patches

Le point de vue agrégé

- ▶ Relire les NL-Means comme la recherche d'un noyau local optimal, une combinaison optimale de pixels
- ▶ Cadre de l'agrégation statistique
- ▶ Point de vue différent et des résultats nouveaux

Plan

Méthodes à noyaux et NL-Means

Agrégation d'estimateurs

Agrégation de patches

Plan

Méthodes à noyaux et NL-Means

- Image, bruit et méthodes à noyaux

- Patches

- NL-Means et interprétations

Agrégation d'estimateurs

Agrégation de patches

Images, bruit et estimation

f : Image idéale $N \times N$

- Pour un pixel $i = (i_1, i_2) \in \llbracket 1, N \rrbracket^2, f(i) \in \mathbb{R}$
- Perte L_2 (perte quadratique), norme associée : $\| \cdot \|$

Images, bruit et estimation



f : Image idéale $N \times N$

- Pour un pixel $i = (i_1, i_2) \in \llbracket 1, N \rrbracket^2, f(i) \in \mathbb{R}$
- Perte L_2 (perte quadratique), norme associée : $\| \cdot \|$

Observation bruitée

- $Y(i) = f(i) + \sigma \varepsilon(i)$
- ε bruit gaussien standard i.i.d. et σ^2 connue
- Autres bruits possibles...

Images, bruit et estimation



f : Image idéale $N \times N$

- Pour un pixel $i = (i_1, i_2) \in \llbracket 1, N \rrbracket^2, f(i) \in \mathbb{R}$
- Perte L_2 (perte quadratique), norme associée : $\| \cdot \|$

Observation bruitée

- $Y(i) = f(i) + \sigma \varepsilon(i)$
- ε bruit gaussien standard i.i.d. et σ^2 connue
- Autres bruits possibles...

Estimation

- Estimer $f(i)$ par $\hat{f}(i)$ à partir Y
- Comportement non local possible...

Images, bruit et estimation



f : Image idéale $N \times N$

- Pour un pixel $i = (i_1, i_2) \in \llbracket 1, N \rrbracket^2, f(i) \in \mathbb{R}$
- Perte L_2 (perte quadratique), norme associée : $\| \cdot \|$

Observation bruitée

- $Y(i) = f(i) + \sigma \varepsilon(i)$
- ε bruit gaussien standard i.i.d. et σ^2 connue
- Autres bruits possibles...

Estimation

- Estimer $f(i)$ par $\hat{f}(i)$ à partir Y
- Comportement non local possible...

Méthodes à noyaux

Méthode à noyaux générique

- ▶ Estimer $f(i)$ par moyennage $\hat{f}(i) = \sum_{k \in \llbracket 1, N \rrbracket^2} \theta_{i,k} Y_k$
- ▶ Les poids $\theta_{i,k}$ peuvent (vont) dépendre de la position et de Y

Méthodes à noyaux

Méthode à noyaux générique

- ▶ Estimer $f(i)$ par moyennage $\hat{f}(i) = \sum_{k \in \llbracket 1, N \rrbracket^2} \theta_{i,k} Y_k$
- ▶ Les poids $\theta_{i,k}$ peuvent (vont) dépendre de la position et de Y

Noyau classique

- ▶ $\theta_{i,k} = \frac{K_h(i - k)}{\sum_{k'} K_h(i - k')}$ (pas de dépendance en Y)
 - ▶ Exemple gaussien $K_h(i) = e^{-(i_1^2 + i_2^2)/2h^2}$
 - ▶ Utilise la proximité spatiale uniquement


Méthodes à noyaux

Méthode à noyaux générique

- ▶ Estimer $f(i)$ par moyennage $\hat{f}(i) = \sum_{k \in \llbracket 1, N \rrbracket^2} \theta_{i,k} Y_k$
- ▶ Les poids $\theta_{i,k}$ peuvent (vont) dépendre de la position et de Y

Noyau classique

- ▶ $\theta_{i,k} = \frac{K_h(i - k)}{\sum_{k'} K_h(i - k')}$ (pas de dépendance en Y)



- ▶ Exemple gaussien $K_h(i) = e^{-(i_1^2 + i_2^2)/2h^2}$
- ▶ Utilise la proximité spatiale uniquement

Noyaux dépendants des données

Exemples

- ▶ Noyaux à fenêtre adaptative
- ▶ Seuillage en \star -let (dépendance complexe des poids)
- ▶ Filtrage bilatéral (dépendant de différences pixel à pixel)

Noyaux dépendants des données

Exemples

- ▶ Noyaux à fenêtre adaptative
- ▶ Seuillage en \star -let (dépendance complexe des poids)
- ▶ Filtrage bilatéral (dépendant de différences pixel à pixel)

Filtrage bilatéral (Tomasi et al. [TM98])

- ▶
$$\theta_{i,k} = \frac{K_h(i, k) \times K'_h(Y(i) - Y(k))}{\sum_{k'} K_h(i - k', i - k') \times K'_h(Y(i) - Y(k'))}$$
- ▶ Version gaussienne :
$$\theta_{i,k} = \frac{e^{-\frac{(i_1 - k_1)^2 + (i_2 - k_2)^2}{2h^2}} \times e^{-\frac{(Y(i) - Y(k))^2}{2h'^2}}}{\sum_{k'} e^{-\frac{(i_1 - k'_1)^2 + (i_2 - k'_2)^2}{2h^2}} \times e^{-\frac{(Y(i) - Y(k'))^2}{2h'^2}}}$$
 - ▶ Intuition : moyenner des pixels proches à la fois en distance et en valeur
 - ▶ Problème : non robuste car trop local...

Noyaux dépendants des données

Exemples

- ▶ Noyaux à fenêtre adaptative
- ▶ Seuillage en \star -let (dépendance complexe des poids)
- ▶ Filtrage bilatéral (dépendant de différences pixel à pixel)

Filtrage bilatéral (Tomasi et al. [TM98])

- ▶
$$\theta_{i,k} = \frac{K_h(i, k) \times K'_{h'}(Y(i) - Y(k))}{\sum_{k'} K_{h'}(i - k', i - k') \times K'_{h'}(Y(i) - Y(k'))}$$
- ▶ Version gaussienne :
$$\theta_{i,k} = \frac{e^{-\frac{(i_1 - k_1)^2 + (i_2 - k_2)^2}{2h^2}} \times e^{-\frac{(Y(i) - Y(k))^2}{2h'^2}}}{\sum_{k'} e^{-\frac{(i_1 - k'_1)^2 + (i_2 - k'_2)^2}{2h^2}} \times e^{-\frac{(Y(i) - Y(k'))^2}{2h'^2}}}$$



- ▶ Intuition : moyenner des pixels proches à la fois en distance et en valeur
- ▶ Problème : non robuste car trop local...

Patches

Patch

- ▶ Patch : version moins locale que la valeur d'un pixel
- ▶ $P(f)(i)$: Patch (=sous-image) centré en i , de largeur W :
$$P(f)(i)(j) = f(i_1+j_1, i_2+j_2) \text{ avec } -\frac{W-1}{2} \leq j_1, j_2 \leq \frac{W-1}{2}$$

Patches

Patch

- ▶ Patch : version moins locale que la valeur d'un pixel
- ▶ $P(f)(i)$: Patch (=sous-image) centré en i , de largeur W :
$$P(f)(i)(j) = f(i_1+j_1, i_2+j_2) \text{ avec } -\frac{W-1}{2} \leq j_1, j_2 \leq \frac{W-1}{2}$$

Patch et images

- ▶ $f \mapsto P(f)$ à une image f associe la collection de patches $P(f)$
- ▶ Relèvement : f est 1-D et $P(f)$ est W^2 -D
- ▶ Reprojection d'une collection de patches $P(f)$ vers une image \tilde{f}

Patches

Patch

- ▶ Patch : version moins locale que la valeur d'un pixel
- ▶ $P(f)(i)$: Patch (=sous-image) centré en i , de largeur W :
$$P(f)(i)(j) = f(i_1+j_1, i_2+j_2) \text{ avec } -\frac{W-1}{2} \leq j_1, j_2 \leq \frac{W-1}{2}$$

Patch et images

- ▶ $f \mapsto P(f)$ à une image f associe la collection de patches $P(f)$
- ▶ Relèvement : f est 1-D et $P(f)$ est W^2 -D
- ▶ Reprojection d'une collection de patches $P(f)$ vers une image \tilde{f}

Patch et estimation

- ▶ Problème d'estimation : Estimation de la collection de patches $P(f)$ à partir de la collection de patches $P(Y)$
- ▶ Problème très différent de l'estimation de $P(f)$ à partir de $P(f) + \sigma\epsilon$ (structure du bruit différente)

Patches

Patch

- ▶ Patch : version moins locale que la valeur d'un pixel
- ▶ $P(f)(i)$: Patch (=sous-image) centré en i , de largeur W :
$$P(f)(i)(j) = f(i_1+j_1, i_2+j_2) \text{ avec } -\frac{W-1}{2} \leq j_1, j_2 \leq \frac{W-1}{2}$$

Patch et images

- ▶ $f \mapsto P(f)$ à une image f associe la collection de patches $P(f)$
- ▶ Relèvement : f est 1-D et $P(f)$ est W^2 -D
- ▶ Reprojection d'une collection de patches $P(f)$ vers une image \tilde{f}

Patch et estimation

- ▶ Problème d'estimation : Estimation de la collection de patches $P(f)$ à partir de la collection de patches $P(Y)$
- ▶ Problème très différent de l'estimation de $P(f)$ à partir de $P(f) + \sigma\varepsilon$ (structure du bruit différente)

Méthodes à patches

Méthodes à noyaux et à patches

- Estimation par moyennage de patches :

$$\widehat{P(f)}(i)(j) = \sum_k \theta_{i,k} P(Y)(k)(j)$$

- Patches = inutiles si les $\theta_{i,k}$ ne dépendent pas de $P(Y)$!

Méthodes à patches

Méthodes à noyaux et à patches

- Estimation par moyennage de patches :

$$\widehat{P(f)}(i)(j) = \sum_k \theta_{i,k} P(Y)(k)(j)$$

- Patches = inutiles si les $\theta_{i,k}$ ne dépendent pas de $P(Y)$!

Intuition

- Utiliser des poids tenant compte de la similarité des patches :
 - Patch $P_{i_0} = P(Y)(i_0)$ à débruiter
 - Patches similaires, utiles : poids importants
 - Patches moins similaires, moins utiles : poids faibles
 - Patches très différents, inutiles : poids quasi nuls

Méthodes à patches

Méthodes à noyaux et à patches

- Estimation par moyennage de patches :

$$\widehat{P(f)}(i)(j) = \sum_k \theta_{i,k} P(Y)(k)(j)$$

- Patches = inutiles si les $\theta_{i,k}$ ne dépendent pas de $P(Y)$!

Intuition

- Utiliser des poids tenant compte de la similarité des patches :



- Patch $P_{i_0} = P(Y)(i_0)$ à débruiter
- Patches similaires, utiles : poids importants
- Patches moins similaires, moins utiles : poids faibles
- Patches très différents, inutiles : poids quasi nuls

NL-Means

NL-Means (Buadès, Coll and Morel)

- ▶ Choisir une mesure de dissimilarité D entre patches
- ▶ Utiliser des poids $\theta_{i,k} = \frac{K(D(P_i, P_k))}{\sum_{k'} K(D(P_i, P_{k'}))}$
- ▶ Choisir $D(P_i, P_k) = \|P_i - P_k\|$ pour mesurer la dissimilarité, un noyau gaussien $K(x) = \exp(-x^2/\beta)$ et une température β

NL-Means

NL-Means (Buadès, Coll and Morel)

- ▶ Choisir une mesure de dissimilarité D entre patches
- ▶ Utiliser des poids $\theta_{i,k} = \frac{K(D(P_i, P_k))}{\sum_{k'} K(D(P_i, P_{k'}))}$
- ▶ Choisir $D(P_i, P_k) = \|P_i - P_k\|$ pour mesurer la dissimilarité, un noyau gaussien $K(x) = \exp(-x^2/\beta)$ et une température β

Résultats

- ▶ Méthode intuitivement simple, efficace et pas trop lente
- ▶ Performance proche de l'état de l'art

NL-Means

NL-Means (Buadès, Coll and Morel)

- ▶ Choisir une mesure de dissimilarité D entre patches
- ▶ Utiliser des poids $\theta_{i,k} = \frac{K(D(P_i, P_k))}{\sum_{k'} K(D(P_i, P_{k'}))}$
- ▶ Choisir $D(P_i, P_k) = \|P_i - P_k\|$ pour mesurer la dissimilarité, un noyau gaussien $K(x) = \exp(-x^2/\beta)$ et une température β

Résultats

- ▶ Méthode intuitivement simple, efficace et pas trop lente
- ▶ Performance proche de l'état de l'art

Variations

- ▶ Adapter automatiquement la zone de recherche (Kervrann et al. [KB06])
- ▶ Polynôme local d'ordre plus élevé (Takeda et al. [TFM07])
- ▶ Autres mesures de similarité (Guichard et al. [APG07])

NL-Means

NL-Means (Buadès, Coll and Morel)

- ▶ Choisir une mesure de dissimilarité D entre patches
- ▶ Utiliser des poids $\theta_{i,k} = \frac{K(D(P_i, P_k))}{\sum_{k'} K(D(P_i, P_{k'}))}$
- ▶ Choisir $D(P_i, P_k) = \|P_i - P_k\|$ pour mesurer la dissimilarité, un noyau gaussien $K(x) = \exp(-x^2/\beta)$ et une température β

Résultats

- ▶ Méthode intuitivement simple, efficace et pas trop lente
- ▶ Performance proche de l'état de l'art

Variations

- ▶ Adapter automatiquement la zone de recherche (Kervrann et al. [KB06])
- ▶ Polynôme local d'ordre plus élevé (Takeda et al. [TFM07])
- ▶ Autres mesures de similarité (Guichard et al. [APG07])

Interprétation(s) des NL-Means

NL-Means au patch i

$$\widehat{P(f)}(i) = \sum_k \frac{e^{-\frac{1}{\beta} \|P(Y)(i) - P(Y)(k)\|^2}}{\sum_{k'} e^{-\frac{1}{\beta} \|P(Y)(i) - P(Y)(k')\|^2}} P(Y)(k)$$

Interprétation(s) des NL-Means

NL-Means au patch i

$$\widehat{P(f)}(i) = \sum_k \frac{e^{-\frac{1}{\beta} \|P(Y)(i) - P(Y)(k)\|^2}}{\sum_{k'} e^{-\frac{1}{\beta} \|P(Y)(i) - P(Y)(k')\|^2}} P(Y)(k)$$

Diffusion / Lissage sur des Variétés

- Explication intuitive mais les preuves demandent des hypothèses fortes [Bua06]
- Variante sur des graphes [Pey08], des variétés [TB09]

Interprétation(s) des NL-Means

NL-Means au patch i

$$\widehat{P(f)}(i) = \sum_k \frac{e^{-\frac{1}{\beta} \|P(Y)(i) - P(Y)(k)\|^2}}{\sum_{k'} e^{-\frac{1}{\beta} \|P(Y)(i) - P(Y)(k')\|^2}} P(Y)(k)$$

Diffusion / Lissage sur des Variétés

- Explication intuitive mais les preuves demandent des hypothèses fortes [Bua06]
- Variante sur des graphes [Pey08], des variétés [TB09]

Modèle pseudo bayésien

- Modèle d'observation (faux) : $P(Y)(i) = P(Y)(k) + \sqrt{\beta/2}\varepsilon$
- Loi a priori uniforme sur les $P(Y)(k)$

Interprétation(s) des NL-Means

NL-Means au patch i

$$\widehat{P(f)}(i) = \sum_k \frac{e^{-\frac{1}{\beta} \|P(Y)(i) - P(Y)(k)\|^2}}{\sum_{k'} e^{-\frac{1}{\beta} \|P(Y)(i) - P(Y)(k')\|^2}} P(Y)(k)$$

Diffusion / Lissage sur des Variétés

- Explication intuitive mais les preuves demandent des hypothèses fortes [Bua06]
- Variante sur des graphes [Pey08], des variétés [TB09]

Modèle pseudo bayésien

- Modèle d'observation (faux) : $P(Y)(i) = P(Y)(k) + \sqrt{\beta/2}\epsilon$
- Loi a priori uniforme sur les $P(Y)(k)$

Zone de recherche et limites de la méthodes

Hypothèse sur l'image et zone de recherche

- ▶ Hypothèses fortes : stationnaires et β -mélangeants (vraies pour les textures ...) [Bua06]

Zone de recherche et limites de la méthodes

Hypothèse sur l'image et zone de recherche

- ▶ Hypothèses fortes : stationnaires et β -mélangeants (vraies pour les textures ...) [Bua06]
- ▶ $\beta \rightarrow 0$ (théorie) : [BCM05]
 $\beta = 12\sigma^2$? est-ce un bon choix ?


Zone de recherche et limites de la méthodes

Hypothèse sur l'image et zone de recherche

- ▶ Hypothèses fortes : stationnaires et β -mélangeants (vraies pour les textures ...) [Bua06]
- ▶ $\beta \rightarrow 0$ (théorie) : [BCM05]
 $\beta = 12\sigma^2$? est-ce un bon choix ?
- ▶ Zone de recherche = image entière (en théorie) : mais trop long, on choisit une petite zone de recherche (ex : $R = 21$)

Zone de recherche et limites de la méthodes

Hypothèse sur l'image et zone de recherche




- Hypothèses fortes : stationnaires et β -mélangeants (vraies pour les textures ...) [Bua06]
- $\beta \rightarrow 0$ (théorie) : [BCM05]
 $\beta = 12\sigma^2$? est-ce un bon choix ?
- Zone de recherche = image entière (en théorie) : mais trop long, on choisit une petite zone de recherche (ex : $R = 21$)

Attention au choix de R


PSNR for varying R in the NL-means procedure (central weight max)

$\sigma=100$, $S=5$, optimised for $\beta=3\sigma^2:3\sigma^2:72\sigma^2$



Attention au choix de R (II)

PSNR for varying R in the NL-means procedure (central weight max)

 $\sigma=50, S=5$, optimised for $\beta=3\sigma^2:3\sigma^2:72\sigma^2$ 

NL-Means et meilleur noyau

Un noyau local optimisé

- ▶ NL-Means produit un noyau local qui s'adapte à la géométrie locale

NL-Means et meilleur noyau

Un noyau local optimisé



- NL-Means produit un noyau local qui s'adapte à la géométrie locale


Un noyau local optimal ?

- Peut-on comparer les NL-Means au meilleur noyau local :

$$\mathbb{E}(\|f - \hat{f}\|^2) \leq C \arg \min_{\theta} \underbrace{\sum_i |f(i) - \sum_k \theta_{i,k} f(k)|^2}_{\text{biais}} + \underbrace{N^2 \sigma^2 \|\theta\|^2}_{\text{variance}} ?$$

NL-Means et meilleur noyau

Un noyau local optimisé



- NL-Means produit un noyau local qui s'adapte à la géométrie locale

Un noyau local optimal ?

- Peut-on comparer les NL-Means au meilleur noyau local :

$$\mathbb{E}(\|f - \hat{f}\|^2) \leq C \arg \min_{\theta} \underbrace{\sum_i |f(i) - \sum_k \theta_{i,k} f(k)|^2}_{\text{biais}} + \underbrace{N^2 \sigma^2 \|\theta\|^2}_{\text{variance}} ?$$

Plan

Méthodes à noyaux et NL-Means

Agrégation d'estimateurs

- Estimateurs initiaux et agrégation

- Agrégation PAC-Bayésienne

- Outils de preuve

Agrégation de patchs

Estimateurs initiaux et agrégation

Modèle et estimateurs initiaux

- ▶ $Y = f + \sigma\varepsilon$ de taille $W \times W$
- ▶ $\{P_k\}$ collection de M estimateur initiaux de f

Estimateurs initiaux et agrégation

Modèle et estimateurs initiaux

- ▶ $Y = f + \sigma\varepsilon$ de taille $W \times W$
- ▶ $\{P_k\}$ collection de M estimateur initiaux de f

Agrégation

- ▶ Estimer f par combinaisons linéaires : $\hat{f} = P_\theta = \sum_k \theta_k P_k$
- ▶ Procédure d'agrégation : manière de choisir θ à partir de Y
- ▶ Notations : $e_k = (0, \dots, 0, 1, 0, \dots, 0) \in \mathbb{R}^M$ et δ_k mesure de Dirac associée sur \mathbb{R}^M

Estimateurs initiaux et agrégation

Modèle et estimateurs initiaux

- ▶ $Y = f + \sigma\varepsilon$ de taille $W \times W$
- ▶ $\{P_k\}$ collection de M estimateur initiaux de f

Agrégation

- ▶ Estimer f par combinaisons linéaires : $\hat{f} = P_\theta = \sum_k \theta_k P_k$
- ▶ Procédure d'agrégation : manière de choisir θ à partir de Y
- ▶ Notations : $e_k = (0, \dots, 0, 1, 0, \dots, 0) \in \mathbb{R}^M$ et δ_k mesure de Dirac associée sur \mathbb{R}^M

Inégalités de type oracle

- ▶ Résultat typique : agrégation « optimale » sur une classe Θ ,

$$\mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq C \inf_{\theta \in \Theta} \left[\|f - P_\theta\|^2 + \sigma^2 V(\theta) \right]$$

- ▶ C , Θ et V dépendent de la procédure

Estimateurs initiaux et agrégation

Modèle et estimateurs initiaux

- ▶ $Y = f + \sigma\varepsilon$ de taille $W \times W$
- ▶ $\{P_k\}$ collection de M estimateur initiaux de f

Agrégation

- ▶ Estimer f par combinaisons linéaires : $\hat{f} = P_\theta = \sum_k \theta_k P_k$
- ▶ Procédure d'agrégation : manière de choisir θ à partir de Y
- ▶ Notations : $e_k = (0, \dots, 0, 1, 0, \dots, 0) \in \mathbb{R}^M$ et δ_k mesure de Dirac associée sur \mathbb{R}^M

Inégalités de type oracle

- ▶ Résultat typique : agrégation « optimale » sur une classe Θ ,

$$\mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq C \inf_{\theta \in \Theta} \left[\|f - P_\theta\|^2 + \sigma^2 V(\theta) \right]$$

- ▶ C , Θ et V dépendent de la procédure

Procédures d'agrégation

Pénalisation AIC/BIC

- Sélection par pénalisation proportionnelle à la dimension :

$$\hat{\theta} = \arg \min_{\theta} \|Y - P_{\theta}\|^2 + \lambda \|\theta\|_0$$

- Optimisation numérique très difficile...

Procédures d'agrégation

Pénalisation AIC/BIC

- Sélection par pénalisation proportionnelle à la dimension :

$$\hat{\theta} = \arg \min_{\theta} \|Y - P_{\theta}\|^2 + \lambda \|\theta\|_0$$

- Optimisation numérique très difficile...

Pénalisation ℓ^1

- Sélection par pénalisation proportionnelle à la norme ℓ^1 :

$$\hat{\theta} = \arg \min_{\theta} \|Y - P_{\theta}\|^2 + \lambda \|\theta\|_1$$

- Résultats pour des P_k fixes sous des hypothèses de structure fortes

Procédures d'agrégation

Pénalisation AIC/BIC

- Sélection par pénalisation proportionnelle à la dimension :

$$\hat{\theta} = \arg \min_{\theta} \|Y - P_{\theta}\|^2 + \lambda \|\theta\|_0$$

- Optimisation numérique très difficile...

Pénalisation ℓ^1

- Sélection par pénalisation proportionnelle à la norme ℓ^1 :

$$\hat{\theta} = \arg \min_{\theta} \|Y - P_{\theta}\|^2 + \lambda \|\theta\|_1$$

- Résultats pour des P_k fixes sous des hypothèses de structure fortes

Poids exponentiels

- Mélange de solutions pondérées par des poids exponentiels :

$$\hat{f} = \frac{1}{Z} \sum_k e^{-\frac{1}{\beta} \|Y - P_k\|^2} P_k$$

Procédures d'agrégation

Pénalisation AIC/BIC

- Sélection par pénalisation proportionnelle à la dimension :

$$\hat{\theta} = \arg \min_{\theta} \|Y - P_{\theta}\|^2 + \lambda \|\theta\|_0$$

- Optimisation numérique très difficile...

Pénalisation ℓ^1

- Sélection par pénalisation proportionnelle à la norme ℓ^1 :

$$\hat{\theta} = \arg \min_{\theta} \|Y - P_{\theta}\|^2 + \lambda \|\theta\|_1$$

- Résultats pour des P_k fixes sous des hypothèses de structure fortes

Poids exponentiels

- Mélange de solutions pondérées par des poids exponentiels :

$$\hat{f} = \frac{1}{Z} \sum_k e^{-\frac{1}{\beta} \|Y - P_k\|^2} P_k$$

Agrégation PAC-Bayésienne

Pré-requis

- ▶ Estimateurs sans biais \hat{r}_θ de $\mathbb{E}\|f - P_\theta\|^2$ obtenus par Stein
- ▶ Loi a priori π sur $\theta \subset \mathbb{R}^M$

Agrégation PAC-Bayésienne

Pré-requis

- ▶ Estimateurs sans biais \hat{r}_θ de $\mathbb{E}\|f - P_\theta\|^2$ obtenus par Stein
- ▶ Loi a priori π sur $\theta \subset \mathbb{R}^M$

Agrégé PAC-Bayésien

- ▶ Procédure spécifique reposant sur des poids exponentiels
- ▶ Estimateur dépend de π et d'une température β : $\hat{f} = P_{\theta_\pi}$ avec

$$\theta_\pi = \int_{\mathbb{R}^M} \frac{e^{-\frac{1}{\beta} \hat{r}_\theta}}{\int_{\mathbb{R}^M} e^{-\frac{1}{\beta} \hat{r}_{\theta'}} d\pi(\theta')} \theta d\pi(\theta) \in \mathbb{R}^M$$

- ▶ Si l'a priori ne charge que les estimateurs initiaux, $\pi = \sum_k \pi_k \delta_k$, notant $\hat{r}_k = \hat{r}_\theta$ si $\theta = e_k$, alors on retrouve

$$\hat{f} = \sum_k \frac{e^{-\frac{1}{\beta} \hat{r}_k} \pi_k}{\sum_{k'} e^{-\frac{1}{\beta} \hat{r}_{k'}} \pi_{k'}} P_k$$

Agrégation PAC-Bayésienne

Pré-requis

- ▶ Estimateurs sans biais \hat{r}_θ de $\mathbb{E}\|f - P_\theta\|^2$ obtenus par Stein
- ▶ Loi a priori π sur $\theta \subset \mathbb{R}^M$

Agrégé PAC-Bayésien

- ▶ Procédure spécifique reposant sur des poids exponentiels
- ▶ Estimateur dépend de π et d'une température $\beta : \hat{f} = P_{\theta_\pi}$ avec

$$\theta_\pi = \int_{\mathbb{R}^M} \frac{e^{-\frac{1}{\beta} \hat{r}_\theta}}{\int_{\mathbb{R}^M} e^{-\frac{1}{\beta} \hat{r}_{\theta'}} d\pi(\theta')} \theta d\pi(\theta) \in \mathbb{R}^M$$

- ▶ Si l'a priori ne charge que les estimateurs initiaux, $\pi = \sum_k \pi_k \delta_k$, notant $\hat{r}_k = \hat{r}_\theta$ si $\theta = e_k$, alors on retrouve

$$\hat{f} = \sum_k \frac{e^{-\frac{1}{\beta} \hat{r}_k} \pi_k}{\sum_{k'} e^{-\frac{1}{\beta} \hat{r}_{k'}} \pi_{k'}} P_k$$

Résultats théoriques

Hypothèses sur P_k

- ▶ Estimateurs initiaux obtenues par projections (Leung et Barron [LB06])
- ▶ Estimateurs initiaux indépendants de Y (Dalalyan et Tsybakov [DT09])

Résultats théoriques

Hypothèses sur P_k

- ▶ Estimateurs initiaux obtenues par projections (Leung et Barron [LB06])
- ▶ Estimateurs initiaux indépendants de Y (Dalalyan et Tsybakov [DT09])

Inégalité oracle

- ▶ Inégalité oracle « précise » : si $\beta \geq 4\sigma^2$,

$$\mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq \inf_p \int_{\theta \in \mathbb{R}^M} \|f - P_\theta\|^2 dp + \beta \mathcal{K}(p, \pi)$$

où $\mathcal{K}(p, \pi)$ est la divergence de Kullback-Leibler

$$\mathcal{K}(p, \pi) = \begin{cases} p \left(\log \left(\frac{dp}{d\pi} \right) \right) & \text{si } p \ll \pi \\ +\infty & \text{sinon} \end{cases}$$

Résultats théoriques

Hypothèses sur P_k

- ▶ Estimateurs initiaux obtenues par projections (Leung et Barron [LB06])
- ▶ Estimateurs initiaux indépendants de Y (Dalalyan et Tsybakov [DT09])

Inégalité oracle

- ▶ Inégalité oracle « précise » : si $\beta \geq 4\sigma^2$,

$$\mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq \inf_p \int_{\theta \in \mathbb{R}^M} \|f - P_\theta\|^2 dp + \beta \mathcal{K}(p, \pi)$$

où $\mathcal{K}(p, \pi)$ est la divergence de Kullback-Leibler

$$\mathcal{K}(p, \pi) = \begin{cases} p \left(\log \left(\frac{dp}{d\pi} \right) \right) & \text{si } p \ll \pi \\ +\infty & \text{sinon} \end{cases}$$

Choix de la loi a priori

Borne d'erreur et a priori

- ▶ $\mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq \inf_p \int_{\theta \in \mathbb{R}^M} \|f - P_\theta\|^2 dp + \beta \mathcal{K}(p, \pi)$
- ▶ Compromis entre un p concentré autour du θ du meilleur agrégé P_θ et un p proche de π
- ▶ Choisir π pour que cette quantité soit « uniformément » petite

Choix de la loi a priori

Borne d'erreur et a priori

- ▶ $\mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq \inf_p \int_{\theta \in \mathbb{R}^M} \|f - P_\theta\|^2 dp + \beta \mathcal{K}(p, \pi)$
- ▶ Compromis entre un p concentré autour du θ du meilleur agrégé P_θ et un p proche de π
- ▶ Choisir π pour que cette quantité soit « uniformément » petite

Loi a priori discrète (sélection de modèle)

- ▶ $\pi = \frac{1}{M} \sum_k \delta_k : \mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq \inf_k \|f - P_k\|^2 + \beta \log M$
- ▶ « Mieux » que le meilleur estimateur initial

Choix de la loi a priori

Borne d'erreur et a priori

- ▶ $\mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq \inf_p \int_{\theta \in \mathbb{R}^M} \|f - P_\theta\|^2 dp + \beta \mathcal{K}(p, \pi)$
- ▶ Compromis entre un p concentré autour du θ du meilleur agrégé P_θ et un p proche de π
- ▶ Choisir π pour que cette quantité soit « uniformément » petite

Loi a priori discrète (sélection de modèle)

- ▶ $\pi = \frac{1}{M} \sum_k \delta_k : \mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq \inf_k \|f - P_k\|^2 + \beta \log M$
- ▶ « Mieux » que le meilleur estimateur initial

Loi a priori parcimonieuse

- ▶ π : i.i.d. Student ou mélange de gaussienne [DT09]
- ▶ Borne : $\mathbb{E}(\|f - \hat{f}\|^2) \leq \inf_{\theta} (\|f - P_\theta\|^2 + C\beta \|\theta\|_0 \log M)$
- ▶ Mieux que la meilleure agrégation « parcimonieuse »

Choix de la loi a priori

Borne d'erreur et a priori

- ▶ $\mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq \inf_p \int_{\theta \in \mathbb{R}^M} \|f - P_\theta\|^2 dp + \beta \mathcal{K}(p, \pi)$
- ▶ Compromis entre un p concentré autour du θ du meilleur agrégé P_θ et un p proche de π
- ▶ Choisir π pour que cette quantité soit « uniformément » petite

Loi a priori discrète (sélection de modèle)

- ▶ $\pi = \frac{1}{M} \sum_k \delta_k : \mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq \inf_k \|f - P_k\|^2 + \beta \log M$
- ▶ « Mieux » que le meilleur estimateur initial

Loi a priori parcimonieuse

- ▶ π : i.i.d. Student ou mélange de gaussienne [DT09]
- ▶ Borne : $\mathbb{E}(\|f - \hat{f}\|^2) \leq \inf_\theta (\|f - P_\theta\|^2 + C\beta \|\theta\|_0 \log M)$
- ▶ Mieux que la meilleure agrégation « parcimonieuse »

Outils de preuve

Estimateur PAC-Bayésien

$$\blacktriangleright \hat{f} = \int_{\mathbb{R}^M} \frac{e^{-\frac{1}{\beta} \hat{r}_\theta}}{\int_{\mathbb{R}^M} e^{-\frac{1}{\beta} \hat{r}_{\theta'}} d\pi(\theta')} P_\theta d\pi(\theta)$$

\blacktriangleright Théorème : Si $\beta \geq 4\sigma^2$,

$$\mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq \inf_p \int_{\theta \in \mathbb{R}^M} \|f - P_\theta\|^2 dp + \beta \mathcal{K}(p, \pi)$$

Outils de preuve

Estimateur PAC-Bayésien

- ▶ $\hat{f} = \int_{\mathbb{R}^M} \frac{e^{-\frac{1}{\beta} \hat{r}_\theta}}{\int_{\mathbb{R}^M} e^{-\frac{1}{\beta} \hat{r}_{\theta'}} d\pi(\theta')} P_\theta d\pi(\theta)$
- ▶ Théorème : Si $\beta \geq 4\sigma^2$,

$$\mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq \inf_p \int_{\theta \in \mathbb{R}^M} \|f - P_\theta\|^2 dp + \beta \mathcal{K}(p, \pi)$$

Outils

- ▶ Estimateur sans biais du risque de Stein (SURE)
- ▶ Propriétés des mesures de Gibbs (exponentielles), et de la divergence de Kullback-Leibler
- ▶ Forme spécifique des poids

Outils de preuve

Estimateur PAC-Bayésien

- ▶ $\hat{f} = \int_{\mathbb{R}^M} \frac{e^{-\frac{1}{\beta} \hat{r}_\theta}}{\int_{\mathbb{R}^M} e^{-\frac{1}{\beta} \hat{r}_{\theta'}} d\pi(\theta')} P_\theta d\pi(\theta)$
- ▶ Théorème : Si $\beta \geq 4\sigma^2$,

$$\mathbb{E} \left(\|f - \hat{f}\|^2 \right) \leq \inf_p \int_{\theta \in \mathbb{R}^M} \|f - P_\theta\|^2 dp + \beta \mathcal{K}(p, \pi)$$

Outils

- ▶ Estimateur sans biais du risque de Stein (SURE)
- ▶ Propriétés des mesures de Gibbs (exponentielles), et de la divergence de Kullback-Leibler
- ▶ Forme spécifique des poids

Plan

Méthodes à noyaux et NL-Means

Agrégation d'estimateurs

Agrégation de patches

- Principe et résultats théoriques

- Estimation PAC-Bayésienne numérique

Agrégation de patches

Patches, estimateurs agrégés, SURE et a priori

- Utiliser le patch $P_i = P(Y)(i)$ comme observation et M patches $P_k = P(Y)(k)$ comme estimateurs primaires
- Estimateurs agrégés : $P_\theta(i) = \sum_k \theta_{i,k} P(Y)(k)$
- Estimateur sans biais $\hat{r}_\theta(i)$ du risque (SURE), ie :
 $\mathbb{E}(\hat{r}_\theta(i)) = \mathbb{E}(\|P(f)(i) - P_\theta(i)\|^2)$ avec

$$\hat{r}_\theta(i) = \|P(Y)(i) - P_\theta(i)\|^2 - W^2(1 - 2\theta_{i,i})\sigma^2$$

- Choix d'une loi a priori π et d'une température β

Agrégation de patches

Patches, estimateurs agrégés, SURE et a priori

- Utiliser le patch $P_i = P(Y)(i)$ comme observation et M patches $P_k = P(Y)(k)$ comme estimateurs primaires
- Estimateurs agrégés : $P_\theta(i) = \sum_k \theta_{i,k} P(Y)(k)$
- Estimateur sans biais $\hat{r}_\theta(i)$ du risque (SURE), ie :
 $\mathbb{E}(\hat{r}_\theta(i)) = \mathbb{E}(\|P(f)(i) - P_\theta(i)\|^2)$ avec

$$\hat{r}_\theta(i) = \|P(Y)(i) - P_\theta(i)\|^2 - W^2(1 - 2\theta_{i,i})\sigma^2$$

- Choix d'une loi a priori π et d'une température β

Estimateur PAC-Bayésien à patches

$$\widehat{P(f)}(i) = \int_{\mathbb{R}^M} \frac{e^{-\frac{1}{\beta} \hat{r}_\theta(i)}}{\int_{\mathbb{R}^M} e^{-\frac{1}{\beta} \hat{r}_{\theta'}(i)} d\pi(\theta')} P_\theta(i) d\pi(\theta)$$

Agrégation de patches

Patches, estimateurs agrégés, SURE et a priori

- Utiliser le patch $P_i = P(Y)(i)$ comme observation et M patches $P_k = P(Y)(k)$ comme estimateurs primaires
- Estimateurs agrégés : $P_\theta(i) = \sum_k \theta_{i,k} P(Y)(k)$
- Estimateur sans biais $\hat{r}_\theta(i)$ du risque (SURE), ie :
 $\mathbb{E}(\hat{r}_\theta(i)) = \mathbb{E}(\|P(f)(i) - P_\theta(i)\|^2)$ avec

$$\hat{r}_\theta(i) = \|P(Y)(i) - P_\theta(i)\|^2 - W^2(1 - 2\theta_{i,i})\sigma^2$$

- Choix d'une loi a priori π et d'une température β

Estimateur PAC-Bayésien à patches

$$\widehat{P(f)}(i) = \int_{\mathbb{R}^M} \frac{e^{-\frac{1}{\beta} \hat{r}_\theta(i)}}{\int_{\mathbb{R}^M} e^{-\frac{1}{\beta} \hat{r}_{\theta'}(i)} d\pi(\theta')} P_\theta(i) d\pi(\theta)$$

Résultats théoriques

Théorème

► Pour $\beta \geq 4\sigma^2$,

$$\begin{aligned} & \mathbb{E} \left(\|P(f)(i) - \widehat{P(f)}(i)\|^2 \right) \\ & \leq \inf_p \int_{\theta} \left(\|P(f)(i) - P_{\theta}(f)(i)\|^2 + W^2 \sigma^2 \|\theta\|^2 \right) dp + \beta \mathcal{K}(p, \pi) \end{aligned}$$

Résultats théoriques

Théorème

- Pour $\beta \geq 4\sigma^2$,

$$\begin{aligned} & \mathbb{E} \left(\|P(f)(i) - \widehat{P(f)}(i)\|^2 \right) \\ & \leq \inf_p \int_{\theta} \left(\|P(f)(i) - P_{\theta}(f)(i)\|^2 + W^2 \sigma^2 \|\theta\|^2 \right) dp + \beta \mathcal{K}(p, \pi) \end{aligned}$$

Travail en cours

- Difficultés techniques sur la partie spécifique aux poids...
- Résultat obtenu si on observe deux version bruitées indépendantes ou avec un « splitting » des pixels...
- Travail en cours pour obtenir le résultat souhaité avec éventuellement une perte dans les constantes (Catoni et al.) et/ou une modification des poids (Leung et Barron)

Résultats théoriques

Théorème ?

- Pour $\beta \geq 4\sigma^2$,

$$\begin{aligned} & \mathbb{E} \left(\|P(f)(i) - \widehat{P(f)}(i)\|^2 \right) \\ & \leq \inf_p \int_{\theta} \left(\|P(f)(i) - P_{\theta}(f)(i)\|^2 + W^2 \sigma^2 \|\theta\|^2 \right) dp + \beta \mathcal{K}(p, \pi) \end{aligned}$$

Travail en cours

- Difficultés techniques sur la partie spécifique aux poids...
- Résultat obtenu si on observe deux version bruitées indépendantes ou avec un « splitting » des pixels...
- Travail en cours pour obtenir le résultat souhaité avec éventuellement une perte dans les constantes (Catoni et al.) et/ou une modification des poids (Leung et Barron)

Loi a priori « discrète »

NL-Means

► Choix $\pi = \sum_k \pi_k \delta_k$

► Agrégation NL-Means pondérées :

$$\widehat{P(f)}(i) = \sum_k \frac{e^{-\frac{1}{\beta} \hat{r}_k(i)} \pi_k}{\sum_{k'} e^{-\frac{1}{\beta} \hat{r}_{k'}(i)} \pi_{k'}} P_k(i)$$

Loi a priori « discrète »

NL-Means

► Choix $\pi = \sum_k \pi_k \delta_k$

► Agrégation NL-Means pondérées :

$$\widehat{P(f)}(i) = \sum_k \frac{e^{-\frac{1}{\beta} \hat{r}_k(i)} \pi_k}{\sum_{k'} e^{-\frac{1}{\beta} \hat{r}_{k'}(i)} \pi_{k'}} P_k(i)$$

Optimalité

► Résultat de type sélection :

$$\begin{aligned} & \mathbb{E} \left(\|P(f)(i) - \widehat{P(f)}(i)\|^2 \right) \\ & \leq \min_k \|P(f)(i) - P(f)(k)\|^2 + W^2 \sigma^2 + \beta \log \frac{1}{\pi_i} \\ & \leq W^2 \sigma^2 + \beta \log \frac{1}{\pi_i} \end{aligned}$$

► (Presque) Mieux que rien...

Loi a priori « discrète »

NL-Means

► Choix $\pi = \sum_k \pi_k \delta_k$

► Agrégation NL-Means pondérées :

$$\widehat{P(f)}(i) = \sum_k \frac{e^{-\frac{1}{\beta} \hat{r}_k(i)} \pi_k}{\sum_{k'} e^{-\frac{1}{\beta} \hat{r}_{k'}(i)} \pi_{k'}} P_k(i)$$

Optimalité

► Résultat de type sélection :

$$\begin{aligned} & \mathbb{E} \left(\|P(f)(i) - \widehat{P(f)}(i)\|^2 \right) \\ & \leq \min_k \|P(f)(i) - P(f)(k)\|^2 + W^2 \sigma^2 + \beta \log \frac{1}{\pi_i} \\ & \leq W^2 \sigma^2 + \beta \log \frac{1}{\pi_i} \end{aligned}$$

► (Presque) Mieux que rien...

Le problème du poids central [SL09a, Sal10]

Rôle(s) du patch central [BC07, ZDW08]

- ▶ $P(Y)(i)$: patch de référence et patch utilisé pour l'estimateur
- ▶ Quel poids pour ce patch central ?

$$\frac{\exp^{-\frac{1}{\beta}\rho_{(k)}(i)}}{\sum_{k'} \exp^{-\frac{1}{\beta}\rho_{(k')}(i)}} P_k$$

Le problème du poids central [SL09a, Sal10]

Rôle(s) du patch central [BC07, ZDW08]

- ▶ $P(Y)(i)$: patch de référence et patch utilisé pour l'estimateur
- ▶ Quel poids pour ce patch central ?

$$\frac{\exp^{-\frac{1}{\beta}\rho_{(k)}(i)}}{\sum_{k'} \exp^{-\frac{1}{\beta}\rho_{(k')}(i)}} P_k$$

4 propositions

- ▶ PAC-Bayésien / Stein : utiliser \hat{r}_θ
 $\rho_{(k)}(i) = \|P(Y)(i) - P(Y)(k)\|^2 - W^2\sigma^2$ et $\rho_{(i)}(i) = W^2\sigma^2$
- ▶ Buadès et al. : remplacer $\rho_{(i)}(i)$ par $\max_{k \neq i} \rho_{(k)}(i)$
- ▶ NL-Means « pur » : $\rho_{(k)}(i) = \|P(Y)(i) - P(Y)(k)\|^2$
- ▶ Zéro : ne pas utiliser le patch central...

Le problème du poids central [SL09a, Sal10]

Rôle(s) du patch central [BC07, ZDW08]

- ▶ $P(Y)(i)$: patch de référence et patch utilisé pour l'estimateur
- ▶ Quel poids pour ce patch central ?

$$\frac{\exp^{-\frac{1}{\beta}\rho_{(k)}(i)}}{\sum_{k'} \exp^{-\frac{1}{\beta}\rho_{(k')}(i)}} P_k$$


4 propositions

- ▶ PAC-Bayésien / Stein : utiliser \hat{r}_θ
 $\rho_{(k)}(i) = \|P(Y)(i) - P(Y)(k)\|^2 - W^2\sigma^2$ et $\rho_{(i)}(i) = W^2\sigma^2$
- ▶ Buadès et al. : remplacer $\rho_{(i)}(i)$ par $\max_{k \neq i} \rho_{(k)}(i)$
- ▶ NL-Means « pur » : $\rho_{(k)}(i) = \|P(Y)(i) - P(Y)(k)\|^2$
- ▶ Zéro : ne pas utiliser le patch central...

Résultats numériques [Sal10]


Résultats numériques [Sal10]

PSNR for varying the central patch weight in the NL-means procedure
($\sigma=5$, $S=5$, $R=13$, optimised for $\beta=3\sigma^2:3\sigma^2:90\sigma^2$)




Résultats numériques [Sal10]

PSNR for varying the central patch weight in the NL-means procedure
($\sigma=5$, $S=5$, $R=13$, optimised for $\beta=3\sigma^2 \cdot 3\sigma^2 \cdot 90\sigma^2$)




$\sigma = 5$

PSNR for varying the central patch weight in the NL-means procedure
($\sigma=10$, $S=5$, $R=13$, optimised for $\beta=3\sigma^2 \cdot 3\sigma^2 \cdot 90\sigma^2$)




$\sigma = 10$

PSNR for varying the central patch weight in the NL-means procedure
($\sigma=20$, $S=5$, $R=13$, optimised for $\beta=3\sigma^2 \cdot 3\sigma^2 \cdot 90\sigma^2$)



$\sigma = 20$

PSNR for varying the central patch weight in the NL-means procedure
($\sigma=50$, $S=5$, $R=13$, optimised for $\beta=3\sigma^2 \cdot 3\sigma^2 \cdot 90\sigma^2$)



$\sigma = 50$

Loi a priori parcimonieuse

A priori continu

- ▶ Loi a priori π chargeant \mathbb{R}^M (ou le simplexe)
- ▶ Utilisation de l'estimé du risque des mélanges !
- ▶ Résultat d'optimalité parmi les mélanges :

$$\begin{aligned} & \mathbb{E} \left(\|P(f)(i) - \widehat{P(f)}(i)\|^2 \right) \\ & \leq \inf_p \left(\int_{\theta} \|P(f)(i) - P_{\theta}(f)(i)\|^2 + W^2 \sigma^2 \|\theta\|^2 + \beta \mathcal{K}(p, \pi) \right) \end{aligned}$$

Loi a priori parcimonieuse

A priori continu

- ▶ Loi a priori π chargeant \mathbb{R}^M (ou le simplexe)
- ▶ Utilisation de l'estimé du risque des mélanges !
- ▶ Résultat d'optimalité parmi les mélanges :

$$\begin{aligned} & \mathbb{E} \left(\|P(f)(i) - \widehat{P(f)}(i)\|^2 \right) \\ & \leq \inf_p \left(\int_{\theta} \|P(f)(i) - P_{\theta}(f)(i)\|^2 + W^2 \sigma^2 \|\theta\|^2 + \beta \mathcal{K}(p, \pi) \right) \end{aligned}$$

A priori parcimonieux

- ▶ A priori π rendant le second membre « uniformément » petit
- ▶ Student (ou mélange de gaussiennes) \rightarrow noyaux parcimonieux
- ▶ Optimalité parmi les noyaux parcimonieux :

$$\begin{aligned} & \mathbb{E} \left(\|P(f)(i) - \widehat{P(f)}(i)\|^2 \right) \\ & \leq \inf_{\theta} \left(\|P(f)(i) - P_{\theta}(f)(i)\|^2 + W^2 \sigma^2 \|\theta\|^2 + c\beta \|\theta\|_0 \log M \right) \end{aligned}$$

Loi a priori parcimonieuse

A priori continu

- ▶ Loi a priori π chargeant \mathbb{R}^M (ou le simplexe)
- ▶ Utilisation de l'estimé du risque des mélanges !
- ▶ Résultat d'optimalité parmi les mélanges :

$$\begin{aligned} & \mathbb{E} \left(\|P(f)(i) - \widehat{P(f)}(i)\|^2 \right) \\ & \leq \inf_p \left(\int_{\theta} \|P(f)(i) - P_{\theta}(f)(i)\|^2 + W^2 \sigma^2 \|\theta\|^2 + \beta \mathcal{K}(p, \pi) \right) \end{aligned}$$

A priori parcimonieux

- ▶ A priori π rendant le second membre « uniformément » petit
- ▶ Student (ou mélange de gaussiennes) \rightarrow noyaux parcimonieux
- ▶ Optimalité parmi les noyaux parcimonieux :

$$\begin{aligned} & \mathbb{E} \left(\|P(f)(i) - \widehat{P(f)}(i)\|^2 \right) \\ & \leq \inf_{\theta} \left(\|P(f)(i) - P_{\theta}(f)(i)\|^2 + W^2 \sigma^2 \|\theta\|^2 + c\beta \|\theta\|_0 \log M \right) \end{aligned}$$

Comment le calculer ?

Une intégrale en grande dimension

- $\hat{f} = P_{\theta_\pi}(i)$ où

$$\theta_\pi = \int_{\mathbb{R}^M} \frac{e^{-\frac{1}{\beta} \hat{r}_\theta}}{\int_{\mathbb{R}^M} e^{-\frac{1}{\beta} \hat{r}_{\theta'}} d\pi(\theta')} \theta d\pi(\theta) \quad .$$

et $\hat{r}_\theta = \|P(Y)(i) - P_\theta(i)\|^2 - W^2(1 - 2\theta_{i,i})\sigma^2$.

- Intégrale de grande dimension similaire à certaines intégrales apparaissant dans le cadre bayésien

Comment le calculer ?

Une intégrale en grande dimension

- $\hat{f} = P_{\theta_\pi}(i)$ où

$$\theta_\pi = \int_{\mathbb{R}^M} \frac{e^{-\frac{1}{\beta} \hat{r}_\theta}}{\int_{\mathbb{R}^M} e^{-\frac{1}{\beta} \hat{r}_{\theta'}} d\pi(\theta')} \theta d\pi(\theta) \quad .$$

et $\hat{r}_\theta = \|P(Y)(i) - P_\theta(i)\|^2 - W^2(1 - 2\theta_{i,i})\sigma^2$.

- Intégrale de grande dimension similaire à certaines intégrales apparaissant dans le cadre bayésien

MCMC

- Approximation par des méthodes de Monte Carlo basées sur la diffusion de Langevin
- Convergence de la chaîne assez lente
- Accélération et amélioration avec une étape de présélection des patches

Comment le calculer ?

Une intégrale en grande dimension

- $\hat{f} = P_{\theta_\pi}(i)$ où

$$\theta_\pi = \int_{\mathbb{R}^M} \frac{e^{-\frac{1}{\beta} \hat{r}_\theta}}{\int_{\mathbb{R}^M} e^{-\frac{1}{\beta} \hat{r}_{\theta'}} d\pi(\theta')} \theta d\pi(\theta) \quad .$$

et $\hat{r}_\theta = \|P(Y)(i) - P_\theta(i)\|^2 - W^2(1 - 2\theta_{i,i})\sigma^2$.

- Intégrale de grande dimension similaire à certaines intégrales apparaissant dans le cadre bayésien

MCMC

- Approximation par des méthodes de Monte Carlo basées sur la diffusion de Langevin
- Convergence de la chaîne assez lente
- Accélération et amélioration avec une étape de présélection des patches

Résultats numériques [SL09b]

Résultats numériques [SL09b]



Originale



Bruitée (22.06 dB)



NL-Means (29.69 dB)



PAC-Bayésien (29.69 dB)

Méthodologie

- ▶ Comparaison avec les NL-Means avec β bien choisi
- ▶ Agrégation PAC-Bayésienne avec un a priori de Student

Résultats numériques [SL09b]



Originale



Bruitée (22.06 dB)



NL-Means (29.69 dB)



PAC-Bayésien (29.69 dB)

Méthodologie

- ▶ Comparaison avec les NL-Means avec β bien choisi
- ▶ Agrégation PAC-Bayésienne avec un a priori de Student

Résultats

- ▶ Résultats similaires à ceux obtenus avec les NL-Means...
- ▶ + stabilité pour les paramètres et marges d'améliorations...

Résultats numériques [SL09b]



Originale



Bruitée (22.06 dB)



NL-Means (29.69 dB)




PAC-Bayésien (29.69 dB)

Méthodologie


- ▶ Comparaison avec les NL-Means avec β bien choisi
- ▶ Agrégation PAC-Bayésienne avec un a priori de Student

Résultats


- ▶ Résultats similaires à ceux obtenus avec les NL-Means...
- ▶ + stabilité pour les paramètres et marges d'améliorations...




Originale




Bruitée (22.06 dB)




NL-Means (29.69 dB)




PAC-Bayésien (29.69 dB)




Originale



Bruitée (22.28 dB)



NL-Means (31.59 dB)



PAC-Bayésien (30.78 dB)



Originale



Bruitée (28.13 dB)



NL-Means (31.19 dB)



PAC-Bayésien (32.20 dB)

Conclusion

Un point de vue agrégé sur les NL-Means

- ▶ Relecture des poids exponentielles et de la distance entre patches
- ▶ Lien avec l'agrégation PAC-Bayésienne et Stein
- ▶ Modification raisonnable pour le poids central
- ▶ Proposition d'une méthode d'agrégation de patches « imitant » le meilleur noyau
- ▶ Outils méthodologiques pour des théorèmes

Conclusion

Un point de vue agrégé sur les NL-Means

- ▶ Relecture des poids exponentielles et de la distance entre patches
- ▶ Lien avec l'agrégation PAC-Bayésienne et Stein
- ▶ Modification raisonnable pour le poids central
- ▶ Proposition d'une méthode d'agrégation de patches « imitant » le meilleur noyau
- ▶ Outils méthodologiques pour des théorèmes

Work in progress...

- ▶ Résultats numériques pour le poids central
- ▶ Résultats préliminaires pour l'agrégation
- ▶ Vers des résultats théoriques avec splitting : « NL-Means » et régression avec random design
- ▶ Cas plus général ???

Conclusion

Un point de vue agrégé sur les NL-Means

- ▶ Relecture des poids exponentielles et de la distance entre patches
- ▶ Lien avec l'agrégation PAC-Bayésienne et Stein
- ▶ Modification raisonnable pour le poids central
- ▶ Proposition d'une méthode d'agrégation de patches « imitant » le meilleur noyau
- ▶ Outils méthodologiques pour des théorèmes

Work in progress...

- ▶ Résultats numériques pour le poids central
- ▶ Résultats préliminaires pour l'agrégation
- ▶ Vers des résultats théoriques avec splitting : « NL-Means » et régression avec random design
- ▶ Cas plus général ???

References I

- ▶ N. Azzabou, N. Paragios, and F. Guichard.
Image denoising based on adapted dictionary computation.
In *ICIP*, pages 109–112, 2007.
- ▶ T. Brox and D. Cremers.
Iterated nonlocal means for texture restoration.
In *SSVM*, volume 4485 of *Lecture Notes in Computer Science*, pages 13–24, 2007.
- ▶ A. Buades, B. Coll, and J-M. Morel.
A review of image denoising algorithms, with a new one.
Multiscale Model. Simul., 4(2) :490–530 (electronic), 2005.
- ▶ A. Buades.
Image and movie denoising by non local means.
PhD thesis, Universitat de les Illes Balears, 2006.
- ▶ A. S. Dalalyan and A. B. Tsybakov.
Sparse regression learning by aggregation and Langevin Monte-Carlo.
In *22th Annual Conference on Learning Theory, COLT*, 2009.

References II

- ▶ C. Kervrann and J. Boulanger.
Optimal spatial adaptation for patch-based image denoising.
IEEE Trans. Image Process., 15(10) :2866–2878, 2006.
- ▶ G. Leung and A.R. Barron.
Information theory and mixing least-squares regressions.
IEEE Trans. Inform. Theory, 52(8) :3396–3410, 2006.
- ▶ G. Peyré.
Image processing with nonlocal spectral bases.
Multiscale Model. Simul., 7(2) :703–730, 2008.
- ▶ J. Salmon.
On two parameters for denoising with non-local means.
IEEE Signal Process. Lett., 2010.
- ▶ J. Salmon and E. Le Pennec.
An aggregator point of view on NL-Means.
In *Proceedings of the SPIE Conference on Mathematical Imaging : Wavelet XIII*, volume 7446, page 74461E. SPIE, 2009.

References III

- ▶ J. Salmon and E. Le Pennec.
NI-means and aggregation procedures.
In *ICIP*, 2009.
- ▶ D. Tschumperlé and L. Brun.
Non-local image smoothing by applying anisotropic diffusion pde's in the space of patches.
In *ICIP*, 2009.
- ▶ H. Takeda, S. Farsiu, and P. Milanfar.
Kernel regression for image processing and reconstruction.
IEEE Trans. Image Process., 16(2) :349–366, 2007.
- ▶ C. Tomasi and R. Manduchi.
Bilateral filtering for gray and color images.
In *ICCV*, page 839, Los Alamitos, CA, USA, 1998. IEEE Computer Society.
- ▶ S. Zimmer, S. Didas, and J. Weickert.
A rotationally invariant block matching strategy improving image denoising with non-local means.
In *LNLA*, 2008.